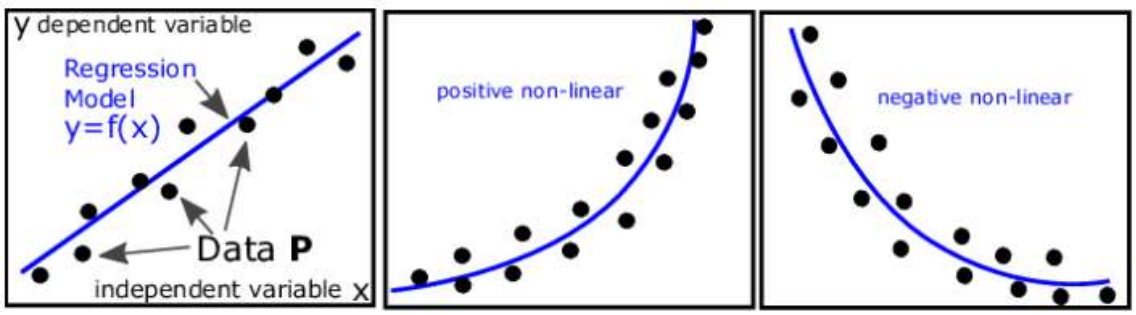
# 1. 선형 회귀(linear regression)

## < 회귀란? >

기계학습의 큰 두 부류는 회귀(regression)와 분류(classification)가 있다. 회귀 문제는 주어진 입력 데이터에 대응하는 값, 즉 예측하고자 하는 값이 연속적인 문제이며 분류 문제는 예측하고자 하는 값이 유한개의 값 중에서 하나인 문제이다. 예를 들어, 사람의 키를 기준으로 몸무게를 예측하는 문제는 회귀 문제이며, 주어진 이미지가 고양이인지 강아지인지를 판별하는 것은 분류 문제이다.

우선 가장 간단한 회귀 문제를 살펴보면서 머신러닝에 대한 개념과 용어들에 익숙해지자. 회귀란 일반적으로 입력데이터 $x$에 대한 연속적인 예측값 $y$ 사이의 함수 $f$를 찾는 문제이다. 즉 $y=f(x)$에서 출력 $y$가 실수이고 입력 $x$도 실수일 때 함수 $f(x)$를 예측하는 것이 회귀이다. 예를 들어 출력이 '가격', '학점', '온도', '무게', '시간'이 될 수 있다. 회귀 기법은 주식 가격 예측, 온도 변화, 전력 수요 변동 등의 연속적인 값을 예측하는데 사용된다. $y=f(x)$를 예측하기 위해서는 우선 $y=f(x)$에서 $x$와 $y$에 대한 데이터 $(x_i,y_i)$가 주어져야 한다. 아래 그림에서 $xy$평면상에서 데이터는 점으로 주어졌다. 이때, 이 데이터를 가장 잘 설명할 수 있는 함수식 $f(x)$를 찾는 문제가 바로 회귀 문제이다. 주어진 데이터로부터 $f(x)$를 찾아낼 수 있다면 데이터로 주어진 값뿐만 아니라, 임의의 값 $x$에 대한 출력값 $y$를 예측할 수 있다.




회귀에서 첫 번째로 결정해야 하는 것은 주어진 데이터를 가장 잘 설명할 수 있는 모델을 설정하는 것이다. 첫 번째 그림에서는 직선의 방정식이 주어진 데이터를 어느 정도는 잘 설명하는 것으로 보이므로 $f(x)$ 를 찾기 위해서 직선의 방정식 $y=ax+b$를 활용할 수 있다. 그러면 문제는 주어진 데이터를 가

장 작은 **오차**로 설명할 수 있는 $a$와 $b$값을 찾는 문제로 귀결된다. 반면 두 번째와 세 번째 그림에서는 직선의 방정식으로 데이터들을 잘 설명하기 어려워 보인다. 이런 경우에는 직선이 아닌 다른 곡선으로 데이터의 추세를 설명하여야 한다. 즉 주어진 데이터를 설명할 '모델'을 설정해야 한다. 두 경우에는 그 모델의 식이 2차 함수일지, 또는 지수함수일지를 결정하는 것부터가 문제이다. 만약 모델을 $y = ax^2 + bx + c$와 같이 이차함수로 설정한다고 하면 이제 회귀 문제는 데이터를 가장 잘 설명할 수 있는 $a, b, c$의 순서쌍을 찾는 것이다.

일차함수 $y = f(x)$ 모델을 선형모델이라고 하며 데이터를 바탕으로 $y = f(x)$를 찾는 것을 **선형 회귀**(linear regression)고 한다. 일차식이 아닌 모든 경우를 **비선형 회귀**(nonlinear regression)라고 한다. 선형 회귀를 사용할 수 있는 예는 다음과 같다.

- 부모의 키와 자녀의 키의 관계
- 면적에 따른 주택의 가격
- 연령에 따른 실업률 예측
- 공부 시간과 학점과의 관계
- CPU속도와 프로그램 실행 시간 예측

## < 선형 회귀의 종류 >

- 단순 선형 회귀: 단순 선형 회귀는 독립 변수($x$)가 하나인 선형 회귀이다. 즉 1변수함수 $y = f(x) = ax + b$으로 주어진 데이터 $(x_i, y_i)$를 최적으로 예측하는 $a$와 $b$를 찾는 문제이다. 이때 $a$와 $b$가 바로 우리가 임의의 값 $x$에 대한 출력 값 $y$에 대한 예측을 하기 위해 최적화 알고리즘이 '학습'하는 매개변수(parameter)이다. 즉, $x$와 $y$는 학습 데이터를 나타내고 $f(x)$는 우리가 찾고자 하는 $x$와 $y$의 함수를 나타낸다.

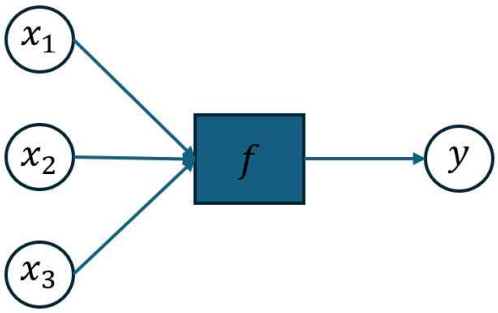
$$f(x) = ax + b$$




- 다중 선형 회귀: 더 복잡한 다중 선형 방정식은 다음과 같다.

$w_0, w_1, w_2, w_3$는 계수 또는 가중치를 나타내며 모델이 학습하려고 하는 매개 변수이다.

$$f(x_1, x_2, x_3) = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3$$




변수 $x_1, x_2, x_3$는 정보의 속성을 나타내며 데이터는 $(x_1, x_2, x_3)$와 이에 대응하는 $y$의 값들로 주어질 것이다. 예를 들어서 매출액 예측의 경우, 이러한 속성에는 라디오, TV, 신문에 대한 회사의 광고 지출이 포함될 수 있다.

$$\text{매출} = w_0 + w_1 \times \text{인터넷 광고} + w_2 \times \text{신문광고} + w_3 \times \text{TV광고}$$

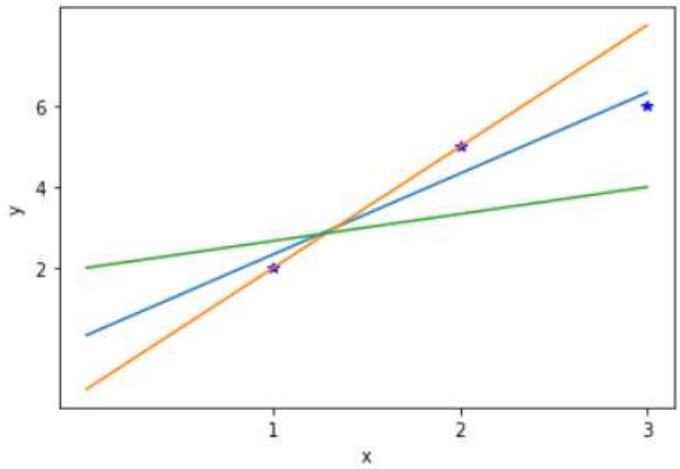
이 경우 선형회귀는 알려진 데이터를 바탕으로 $(w_0, w_1, w_2, w_3)$를 찾는 것이다.

## < 선형 회귀의 원리 >

선형 회귀를 간단하게 설명하기 위하여 다음과 같은 간단한 데이터를 생각하자.

| x | y |
|---|---|
| 1 | 2 |
| 2 | 5 |
| 3 | 6 |

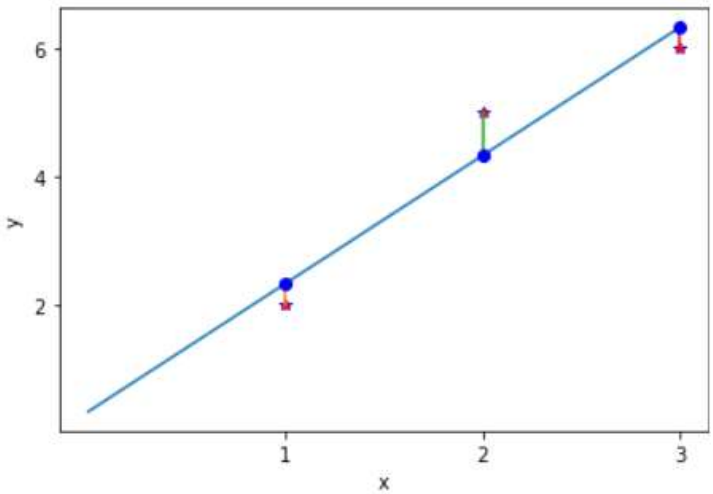
여기서 $x$를 특징 데이터라 하고 $y$는 예측할 값이다. $x$를 입력값, $y$를 출력값 또는 데이터 $x$에 대한 레이블(label)이라고도 한다. 지도학습에서 입력 $x$에 대한 정답 $y$를 주어진 것으로 생각할 수 있다. 주어진 데이터를 $\{(x_i, y_i)\}_{i=1}^{3}$으로 표시할 수 있는데 그러면 데이터는 $(x_1, y_1) = (1,2)$, $(x_2, y_2) = (2,5)$, $(x_3, y_3) = (3,6)$과 같고 이를 좌표평면에 $*$로 나타내면 아래와 같다.




선형 회귀에서는 $x$와 $y$의 간의 관계가 선형관계, 즉 직선의 방정식을 따른다고 가정하므로 이제 문제는 위의 데이터를 최적으로 설명하는 직선을 찾는 것이다. 위의 그래프에는 3개의 직선이 그려져 있는데 선형 회귀에서는 이 중에서 학습 데이터와 가장 잘 맞는 하나의 직선을 선택하게 된다. 직선은 다음과 같이 기울기와 절편으로 나타낼 수 있다.

$$f(x) = ax + b$$

이제 문제는 어떤 직선이 우리가 제공한 데이터와 가장 잘 맞느냐이다. 이것은 실제 데이터와 직선 사이의 간격을 보면 알 수 있다. 간격이 적을수록 직선이 데이터와 잘 맞는다고 할 수 있다.




이 간격을 **오차(error)**라고 한다. 데이터를 가장 잘 설명하기 위해서는 어떤 의미에서 오차의 합이 가장 작은 직선의 방정식을 찾는 것인데 이는 두 가지 방법을 생각할 수 있다. 첫 번째는 오차의 절대값 $|f(x_i) - y_i|$의 평균 값을 고려할 수 있다. 다른 한 방법은 오차의 제곱 $|f(x_i) - y_i|^2$의 평균을 고려할

수도 있다. 수학적으로는 두 가지 모두 의미가 있으나 미분을 사용하여 해석하기 위해서는 절댓값이 없는 **오차 제곱의 평균**(mean square error, MSE)를 고려한다.

어느 방식이든 오차들을 정량화하여 나타낸 함수를 **손실 함수(loss function)** 또는 **비용 함수(cost function)**라고 한다. 우리는 MSE 손실함수를 사용하면.

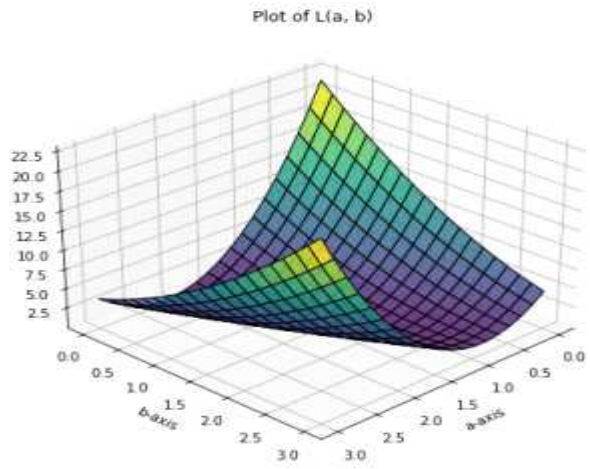
$$Loss(a,b) = \frac{1}{3}\sum_{i=1}^{3}(f(x_i) - y_i)^2 = \frac{1}{3}\{(f(x_1) - y_1)^2 + (f(x_1) - y_2)^2 + (f(x_3) - y_3)^2\}$$

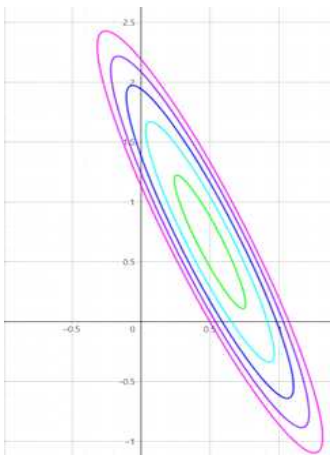
$$= \frac{1}{3}\{(a+b-2)^2 + (2a+b-5)^2 + (3a+b-6)^2\}$$

으로 정의된다. 이를 전개하면

$$Loss(a,b) = \frac{1}{3}(14a^2 + 12ab + 3b^2 - 22a - 10b + 9)$$

이고 이것은 $a$와 $b$에 대한 이변수함수이다. 참고로 이 함수를 $a$와 $b$축에 대해서 3차원 그래프를 그리면 아래와 같이 아래로 볼록한 함수이다. (bowl 모양인데 한쪽 방향으로 눌려져있다.) $L(a,b)$는 $a$만의 함수로 보면 아래로 볼록한 이차함수이고 $b$만의 함수로 생각해도 아래로 볼록한 이차함수이다.



문제는 이변수함수 $L(a,b)$가 최소가 되는 $a$, $b$값 $a^*$, $b^*$를 찾는 것이다. 이것을 argmin이라는 표기법으로 적으면 다음과 같이 된다.

$$a^*, b^* = \arg\min_{a,b} Loss(a,b)$$

## < 학습과 손실 >

머신러닝에서 모델을 **학습**시킨다는 것은 단순히 말하자면 훈련 데이터로부터

**손실 함수를 최소화**하는 파라미터(예를 들어 $a$와$b$)를 학습(결정)하는 것이다. 손실(loss)은 잘못된 예측에 대한 벌점이라 할 수 있다. 즉. 손실은 특정 샘플(데이터)에서 모델의 예측이 얼마나 잘못되었는지를 나타내는 숫자이다. 모델의 예측이 완벽하면 손실은 0이고 그렇지 않으면 손실은 0보다 커진다. 모델 학습의 목표는 모든 샘플에서 평균적으로 가장 작은 손실을 갖는 **가중치(weight, $a$)와 편이(bias, $b$)**를 찾는 것이다.

## 2. 손실 함수를 최소화하는 방법

일반적인 머신러닝 알고리즘은 손실 함수의 값이 최소화되는 방향을 찾아서 매개변수인 $a$와 $b$를 변경하는 작업을 반복한다. 손실 함수가 더 이상 작아지지 않거나 변화가 거의 없어지게 되면 학습이 종료된다. 손실 함수의 값이 작아지는 방향을 어떻게 알 수 있을까?

$$Loss(a,b) = 14a^2 + 12ab + 3b^2 - 22a - 10b + 9$$

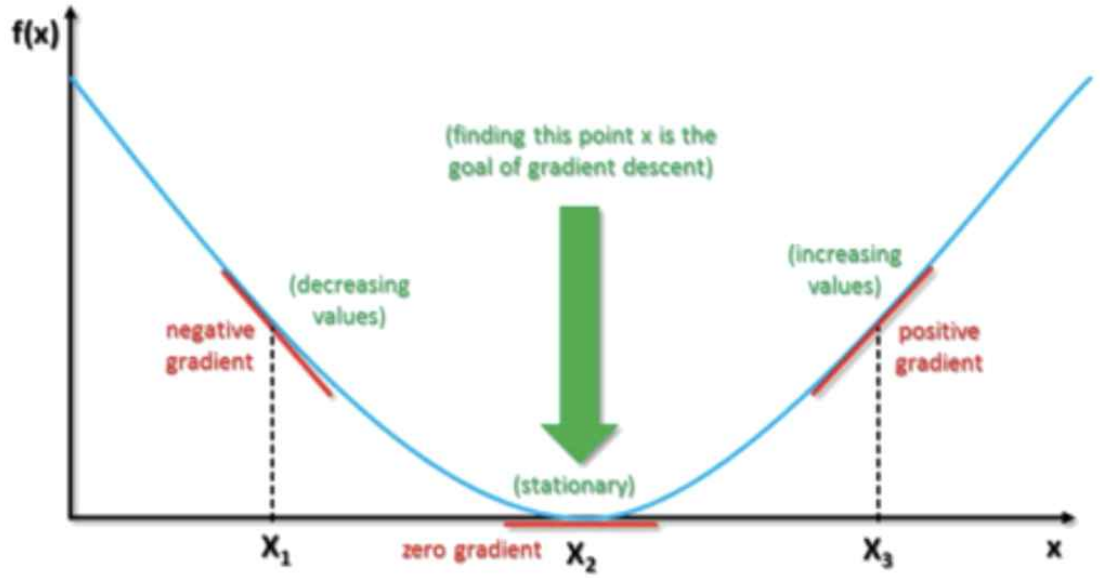
이 함수의 최솟점은 $\nabla L = (28a + 12b - 22, 6b + 12a - 10) = (0,0)$을 만족하는 $a$와 $b$값을 찾으면 된다. 즉, 손실 함수의 최솟점에서 보면 $a$축과 $b$축 방향으로 손실함수의 변화율이 모두 0이므로 두 방정식 $\begin{cases} 28a + 12b - 22 = 0 \\ 6b + 12a - 10 = 0 \end{cases}$ 을 연립하여 $a$, $b$값을 찾는다. 연립방정식의 해는 $a = 1/2$, $b = 2/3$이므로 주어진 데이터를 최적으로 예측하는 선형모델은 $y = 1/2x + 2/3$이 된다. 이제 이 선형방정식을 이용하여 주어진 데이터 이외의 다른 임의의 값 $x$에 대해서도 예측값 $y$를 구할 수 있다.

이처럼 파라미터의 수가 적은 회귀 문제는 편미분을 사용해서 ($\nabla L = 0$) 연립방정식을 풀어 최솟점을 쉽게 찾을 수 있지만, 파라미터의 수가 수백 만~수백 조 정도가 되는 문제에서 연립방정식을 풀어 $L$의 최솟점을 찾는 것은 아무리 좋은 슈퍼컴퓨터를 이용한다고 해도 불가능한 문제가 된다.

### < 경사하강법(gradient decent) >

$L = L(a,b)$의 최솟점 $a^*$, $b^*$를 경사하강법으로 찾는 방법을 설명하기 전에

일반적으로 일변수함수 $y = f(x)$에서 경사하강법을 설명하고 이를 다변수함수에서의 경사하강법으로 일반화시키자.




위 그래프에서 최솟점은 $x_2$로 $f'(x_2) = 0$이다. $x_1$점에서 $x$에 대한 $y$의 변화율, 즉 $f'(x_1) < 0$ 이고 $x_3$점에서 $x$에 대한 $y$의 변화율, 즉 $f'(x_3) > 0$이다. 즉

① $x_1$**에서** $f'(x_1)$**의 방향(이 경우는 음의 방향)으로 나아가면** $y$**값은 증가**

② $x_3$**에서** $f'(x_3)$**의 방향(이 경우는 양의 방향)으로 나아가면** $y$**값은 증가**한다.

어느 경우이든 $f'(x)$**값이 나타내는 방향으로** $x$**값을 변화시키면** $y$**값은 증가**하게 된다. 우리의 목표는 $y$의 값이 감소하는 방향으로 나아가야 하므로 $f'(x)$의 반대 부호 방향, 즉 $-f'(x)$ **방향으로** $x$**값을 변화**시켜 나가야 한다.

이것을 선형근사(linear approximation)의 관점에서 설명하면 다음과 같다. 미분계수의 정의가

$$f'(x) = \lim_{\Delta x \to 0} \frac{\Delta y}{\Delta x}$$

이므로 limit를 생략하고 충분히 작은 $\Delta x\,(\Delta x \approx 0)$에 대해서 생각하면

$$\Delta y \approx f'(x)\Delta x$$

이다. 즉,

$$y\text{의 변화량} \approx (x\text{에 대한 } y\text{의 변화율}) \times (x\text{의 변화량})$$

으로 $y$의 변화를 근사할 수 있다.

예를 들어

$$\text{체중} = f(t),\ t = \text{날짜}$$

의 함수관계가 성립한다고 하자. 만약 하루당 체중의 변화율이 $100g$이라는 것을 알아냈다면, 이것은 $\frac{d\text{체중}}{d\text{날짜}} = \frac{df}{dt} = 100$로 나타낼 수 있다. 단위는 $g$/일이다. 이 때, 3일 뒤의 체중변화는 $\Delta\text{체중} = 100\,(g/\text{일}) \times 3\text{일} = 300g$으로 예측할 수 있을 것이다. 즉 변화율을 알면 짧은 기간 ($\Delta t$ 가 작을 때) 내의 변화량을 예측할 수 있는 것이다. 이상으로

$$\Delta y \approx f'(x)\Delta x$$

에서 우리는 다음을 관찰할 수 있다.

**① $f'(x)$의 부호가 양수일 때 $x$를 증가시키면 즉, $\Delta x > 0$ 이면 $y$의 값은 증가한다.**

**② $f'(x)$의 부호가 음수일 때 $x$를 감소시키면 즉, $\Delta x < 0$ 이면 $y$의 값은 증가한다.**

따라서 $y$의 값을 감소시키기 위해서 우리는 $f'(x)$ 부호와 반대방향으로 $x$를 변화시켜야 한다. 이상을 정리하면 경사하강법은 다음과 같이 정리할 수 있다.

함수 $y = f(x)$의 최솟점 $x^*$에서 충분히 가까운 점 $x_0$에서 시작하여

$$x_{n+1} = x_n - \alpha f'(x_n),\ n = 0, 1, 2, \cdots$$

으로 수열 $\{x_n\}$을 정의하면 $\lim_{n\to\infty} x_n = x^*$이다. 이 때, $\alpha > 0$는 상수이고 학습률(learning rate)을 나타낸다.

예를 들어, $y = f(x) = x^2 - 4x + 5$의 최솟점은 $f'(x) = 2x - 4 = 0$ 인 $x = 2$이다. 한편 $x_0 = 4$, $\alpha = 0.1$ 로 경사하강법을 적용하면

$$x_1 = x_0 - 0.1 \times f'(x_0) = 4 - 0.1 \times 4 = 3.6$$

$$x_2 = x_1 - 0.1 \times f'(x_1) = 3.6 - 0.1 \times 3.2 = 3.28$$

$$\cdots$$

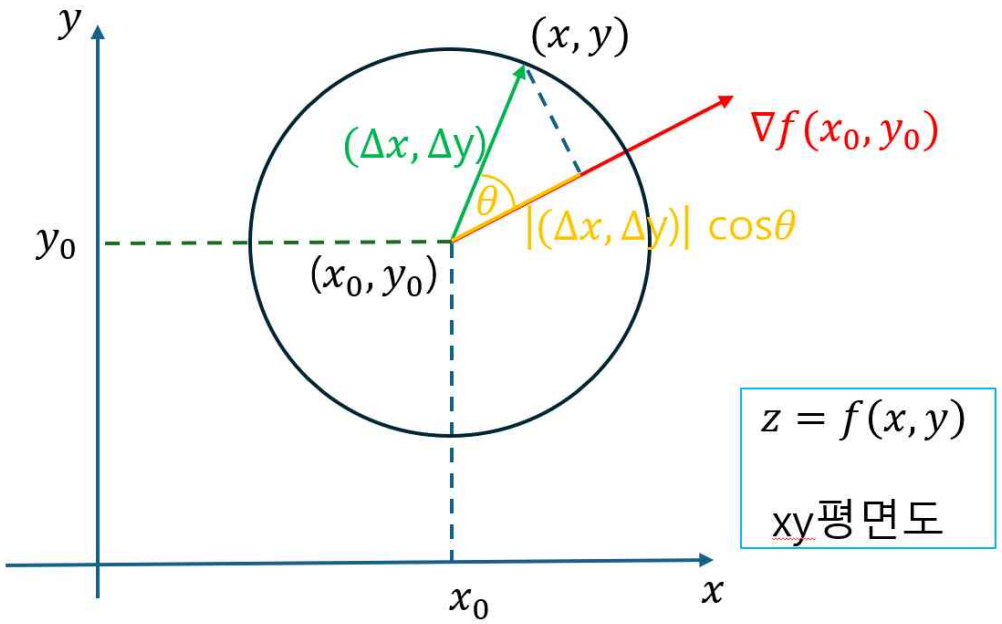
으로 계산할 수 있고 이렇게 생성된 수열 $\{x_n\}$은 최솟점 2로 수렴하게 된다.

## < 다변수함수의 경사하강법 >

이변수함수 $z = f(x,y)$에 대해서 생각해 보자. 일변수함수와 마찬가지로 점 $(x_0, y_0)$에서 $z$의 변화는 다음과 같이 일차식으로 근사할 수 있다.

$$\Delta z \approx \frac{\partial z}{\partial x}(x_0, y_0)\,\Delta x + \frac{\partial z}{\partial y}(x_0, y_0)\,\Delta y$$

$$= \frac{\partial z}{\partial x}(x_0, y_0)\,(x - x_0) + \frac{\partial z}{\partial y}(x_0, y_0)\,(y - y_0)$$




즉, $(x,y) = (x_0, y_0)$에서 함숫값 $z = f(x,y)$의 변화는

**$z$의 변화량 = ($x$에 대한 $z$의 변화량) $\times$($x$의 변화량)**

**+ ($y$에 대한 $z$의 변화량) $\times$($y$의 변화량)**

이다. 내적을 사용해서 나타내면

$$\Delta z \approx \left( \frac{\partial z}{\partial x}(x_0, y_0), \frac{\partial z}{\partial y}(x_0, y_0) \right) \cdot (x - x_0, y - y_0)$$

$$= |\nabla f(x_0, y_0)| \times |(x - x_0, y - y_0)| \times cos\theta$$

이다. 이제 $(x_0, y_0)$에서 시작해서 한 발짝, 즉 $|(x - x_0, y - y_0)| = 1$인 방향으로 나아간다고 할 때, $|(x - x_0, y - y_0)| \times cos\theta$ 가 최대가 되는 방향은 $\cos\theta = 1$인 방향, 즉 $\nabla f(x_0, y_0)$와 같은 방향이다. 반면 $cos\theta = -1$인 방향으로 나아가면 최소가 된다. 즉,

① $\nabla f(x_0, y_0)$ **방향으로 $x$와 $y$값을 변화시키면 $z$는 최대로 증가하고**

② $-\nabla f(x_0, y_0)$ **방향으로 $x$와 $y$값을 변화시키면 $z$는 최대로 감소한다.**

이와 같은 사실로부터 이변수함수에서의 경사하강법을 다음과 같이 정의할 수 있다.

함수 $z = f(x, y)$의 최솟점 $(x^*, y^*)$에서 충분히 가까운 점 $(x_0, y_0)$에서 시작하여

$$(x_{n+1}, y_{n+1}) = (x_n, y_n) - \alpha \nabla f(x_n, y_n), \ n = 0, 1, 2, \cdots$$

으로 점열 $\{(x_n, y_n)\}$을 정의하면, $\lim_{n \to \infty}(x_n, y_n) = (x^*, y^*)$이다. 이 때, $\alpha > 0$는 상수이고 학습률(learning rate)을 나타낸다.

이제

$$Loss(a, b) = 14a^2 + 12ab + 3b^2 - 22a - 10b + 9$$

에 경사하강법을 적용해 보자. 시작점을 $(a, b) = (1, 1)$이라 하고 $\alpha = 0.01$이라 하면,

$$\nabla L = (28a + 12b - 22, 6b + 12a - 10)$$

이므로

$$(a_1, b_1) = (1, 1) - 0.01 \times \nabla L(1, 1) = (1, 1) - 0.01 \times (18, 8) = (0.82, 0.92)$$

이다. 이와 같은 과정을 충분히 진행하면 최솟점 $(1/2, 2/3)$에 도달하는 점열 $\{(a_n, b_n)\}$을 구성할 수 있다.

경사하강 알고리즘은 다변수함수 $z = f(x_1, x_2, \cdots, x_n), n \geq 2$에 대해서 일반화해서 적용할 수 있다. 함수가 유일한 최솟점을 갖는 볼록함수라면 경사하강 알고리즘은 적당히 작은 $\alpha$와 적당한 $x_0$에 대해서 수렴한다.

또한 여기서 혼동하면 안되는 점은 경사하강으로 모델함수 $f$에 대한 최적화를 수행하는 것이 아니라, 모델함수 $f$를 구성하는 파라미터에 대한 손실함수 $L$을 최적화함으로써 모델함수 $f$를 찾는다는 것이다.