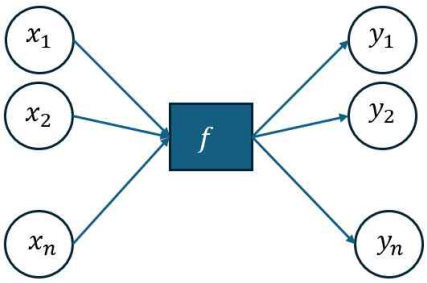
다변수함수

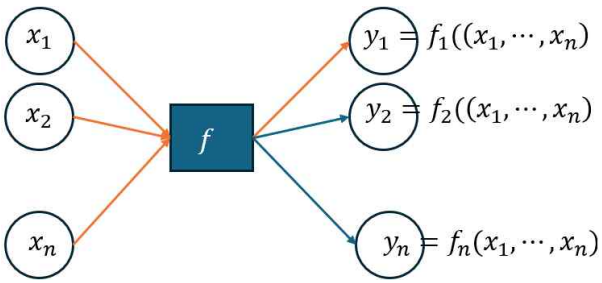
고등학교까지는 독립변수가 x 하나이고 종속변수는 y 하나인 일변수함수에 대해서 배우고 미분과 적분을 생각했다.



그러나 인공지능을 포함한 많은 실제 문제는 결코 일변수함수가 아닌 **다변수 벡터함수**이다. 즉 독립변수 (인공지능에서는 입력변수라고도 한다)가 $(x_1,x_2,\cdots,x_n)$과 같이 n개의 순서쌍(벡터)이고 이에 따르는 종속변수도 $(y_1,y_2,\cdots,y_n)$과 같이 벡터 형태로 나타난다.



이 중에서 종속변수가 하나이고 독립변수가 여러 개인 형태인 $y=f(x_1,x_2,\cdots,x_n)$를 **다변수함수**라고 하고, 종속변수도 벡터 형태로 나타나는 함수 $(y_1,y_2,\cdots,y_n)=f(x_1,x_2,\cdots,x_n)$는 (다변수) **벡터함수**라고 한다. 다변수 벡터함수를 각 종속변수 y_i별로 떼어서 생각하면, 각 종속변수 y_i는 $(x_1,x_2,\cdots,x_n)$의 함수 f_i로 생각할 수 있다. 즉 $y_i=f_i(x_1,x_2,\cdots,x_n)$, $(i=1,2,\cdots,n)$으로 분리해서 생각할 수 있다.



따라서 우선 간단히 독립변수가 (x,y)이고 종속변수가 z인 이변수함수 $z=f(x,y)$에 대해서 생각하고 이를 일반화 시키자.

실수의 순서쌍 (x,y)들의 집합 D의 각 원소 (x,y)에 하나의 실수 값 z를 대응 시키는 대응 규칙 f를 두 변수 x,y의 함수, z를 (x,y)에 대한 f의 값이라고 하고

$$f(x,y) \text{ 또는 } z = f(x,y)$$

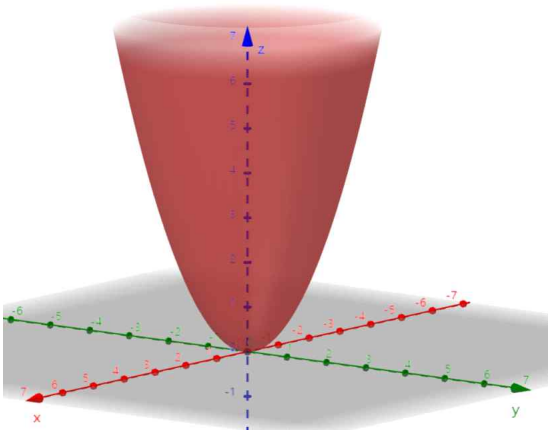
로 나타낸다. 이때, D를 f의 **정의역**(domain), D의 각 원소에 대한 f 의 값의 집합을 **치역**(range)이라고 한다. 그리고 f를 **이변수함수**, x 및 y 를 **독립변수**, z 를 **종속변수**라고 한다.

이변수함수 $z=f(x,y)$의 **그래프**는 실수의 순서모임 (x,y,z)들의 집합

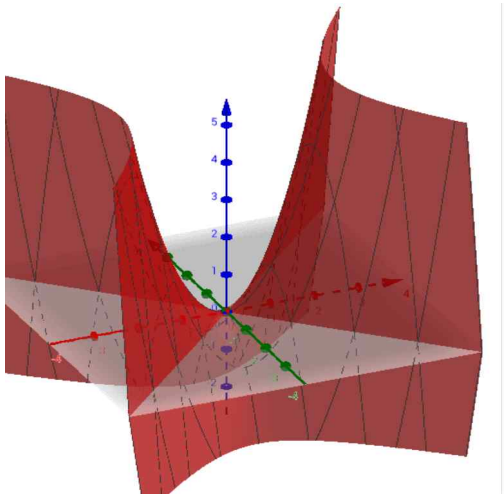
$$G = \{(x,y,z) \mid (x,y) \in D, z = f(x,y)\}$$

이며, 공간의 한 **곡면**을 나타낸다.

예를 들어, $z = f(x,y) = x^2 + y^2$, $z = g(x,y) = x^2 - y^2$ 의 그래프는 다음과 같다.



$z = f(x,y) = x^2 + y^2$



$z = g(x,y) = x^2 - y^2$

삼차원 공간에서 이변수함수의 그래프를 이해하는 방법 중 하나는 이변수함수 $z = f(x,y)$의 그래프가 세 좌표평면과 만나 생기는 **교선**을 생각하는 것이다. $z = f(x,y)$의 그래프가 xz평면과 만나는 교점을 생각해보면, xz평면 위의 점들은 $y=0$이므로 $z = f(x,y)$의 그래프는 xz평면에서 $z = f(x,0)$이 되어 포물선인 $z = x^2$로 나타난다. 같은 방식으로 yz평면과의 교점은 $x=0$을 대입하여 $z = f(0,y) = y^2$으로 나타난다. 한편 $z = f(x,y)$과

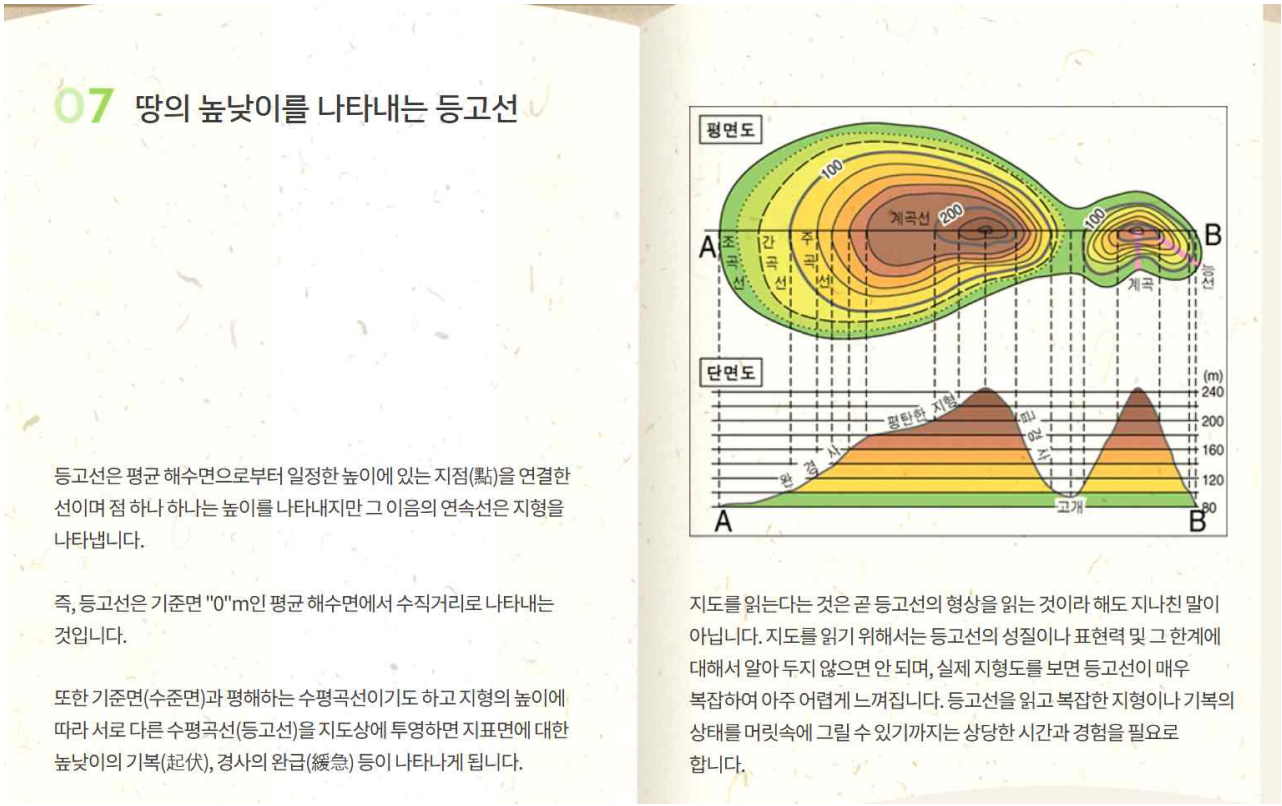
xy평면($z=0$)과의 교점을 구하면 $x^2+y^2=0$ 으로부터 $(x,y)=(0,0)$이 된다. 즉 원점에서 꼭짓점이 생기는 **포물면**이 $z=x^2+y^2$의 그래프이다. $z=g(x,y)=x^2-y^2$의 그래프도 마찬가지로 생각하면, xz평면에서는 $z=x^2$으로 아래로 볼록한 포물선이고, yz편면에서는 $z=-y^2$으로 위로 볼록한 포물선이 된다. xy평면과의 교점은 $x^2-y^2=0$ 으로부터 $y=\pm x$이다. 즉, 그래프는 xy평면과 $y=\pm x$ 직선 상에서 만난다. 이 그래프는 위와 같이 원점 $(0,0,0)$에서 생각할 때 x축 방향으로는 증가하고 y축 방향으로는 감소하는 곡면의 형태를 갖는다. 곡면의 모양이 말안장에서 평평한 부분과 같다고 하여 원점을 안장점(saddle point) 이라고 한다.

함수의 최대-최소 문제 관점에서 보면 $z=x^2+y^2$은 아래로 볼록한 함수(convex function)이고 유일한 극솟점 $(x,y)=(0,0)$에서 최솟값 0을 갖는다는 것을 알 수 있다. 반면 $z=x^2-y^2$은 볼록함수가 아니며 $(x,y)=(0,0)$에서 순간적으로 평평하여 경사도가 0이지만 x축 방향으로 조금 나아가면 함숫값은 증가하고 y축 방향으로는 감소하는 특징을 갖는다. 이러한 함수는 최댓값과 최솟값이 없다는 것을 알 수 있다.

< level curve >

이변수함수의 그래프를 이해하는 대표적인 또 하나의 방법은 xy평면과 평행한 평면으로 그래프를 잘라서 생각하는 것이다. 즉, $z=f(x,y)$의 그래프와 xy평면과 평행한 임의의 평면 $z=c$ 의 교점의 집합 $\{(x,y,c)|f(x,y)=c\}$을 생각하는 것이다. 이 때, 이 교선들을 xy평면으로 **사영**(projection)시킨 집합 $\{(x,y)|f(x,y)=c\}$을 곡면 $z=f(x,y)$의 **등고선** (level curve) 또는 등위선이라 한다. 지도의 등고선, 일기예보의 등압선, 인공위성 지도에서 지구의 온도 분포를 나타내는 등온선 등이 이러한 개념이다. 우리가 종이로 된 지도에서 등고선을 보고 머릿속으로 3차원 지형을 연상해 낼 수 있듯이 등고선은 다변수함수를 이해하는데 중요한 역할을 한다. 등고선으로 해당 지역의 높이를 알 수 있을 뿐만 아니라 등고선 사이의 간격이 좁으면 경사가 급하다는 것을 알 수 있고 등고선을 보고 골짜기인지 능선인지를 파악할 수 있다. 또한 각 지점에서 가장 경사가 가파른

방향은 등고선과 **수직인 방향이라는** 것을 우리는 안다.



07 땅의 높낮이를 나타내는 등고선

등고선은 평균 해수면으로부터 일정한 높이에 있는 지점(點)을 연결한 선이며 점 하나 하나는 높이를 나타내지만 그 이음의 연속선은 지형을 나타냅니다.

즉, 등고선은 기준면 "0"m인 평균 해수면에서 수직거리로 나타내는 것입니다.

또한 기준면(수준면)과 평해하는 수평곡선이기도 하고 지형의 높이에 따라 서로 다른 수평곡선(등고선)을 지도상에 투영하면 지표면에 대한 높낮이의 기복(起伏), 경사의 완급(緩急) 등이 나타나게 됩니다.

지도를 읽는다는 것은 곧 등고선의 형상을 읽는 것이라 해도 지나친 말이 아닙니다. 지도를 읽기 위해서는 등고선의 성질이나 표현력 및 그 한계에 대해서 알아 두지 않으면 안 되며, 실제 지형도를 보면 등고선이 매우 복잡하여 아주 어렵게 느껴집니다. 등고선을 읽고 복잡한 지형이나 기복의 상태를 머릿속에 그릴 수 있기까지는 상당한 시간과 경험을 필요로 합니다.

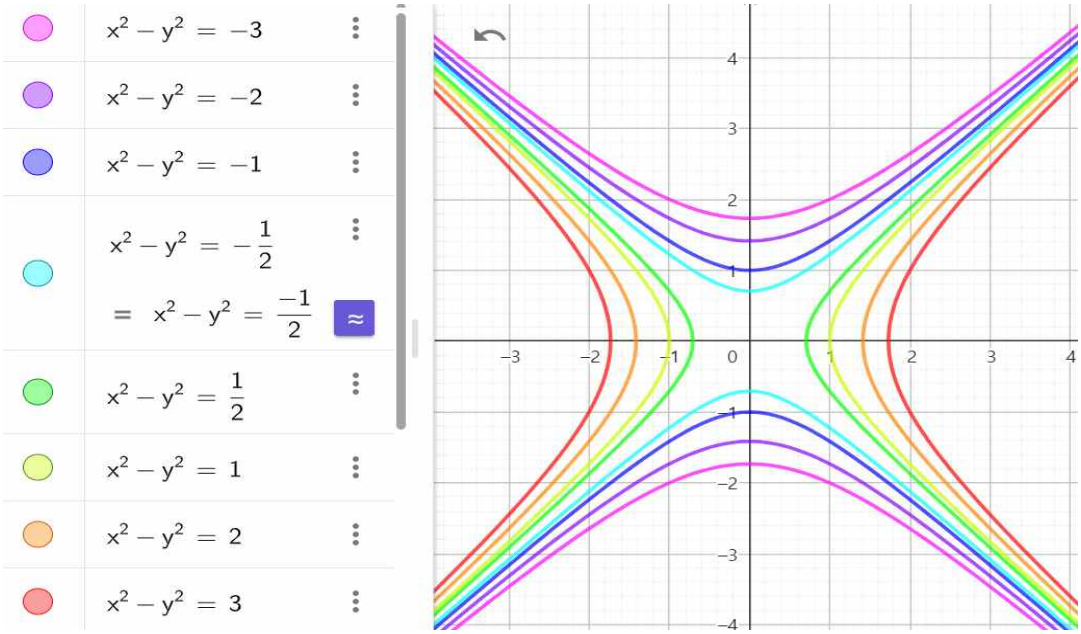
$z = x^2 + y^2$의 등고선을 몇 개 그려보면 다음과 같다.



이러한 등고선을 아주 조밀한 간격으로 연속적으로 그려서 평면을 빈틈없이 c값에 따라 채색하면 우리가 보는 채색된 지도가 될 것이다. 핸드폰이나 컴

퓨터의 화면과 같이 우리가 보는 영상매체도 화면의 각 지점 (x,y)에 대응되는 값과 그 값에 해당하는 색을 대응시키는 colormap 방식으로 영상을 나타낸다고 생각할 수 있다. 다만 차이점은 (x,y)값에 (R,G,B) 세 개의 채널 값을 대응시키는 벡터함수라는 것이다. 이때 이 벡터함수를 $R=R(x,y)$, $G=G(x,y)$, $B=B(x,y)$로 세 개의 이변수함수로 분리하여 생각할 수 있다.

$z=x^2-y^2$의 등고선을 몇 개 그려보면 다음과 같다.



선형회귀에서 손실함수는 이변수함수

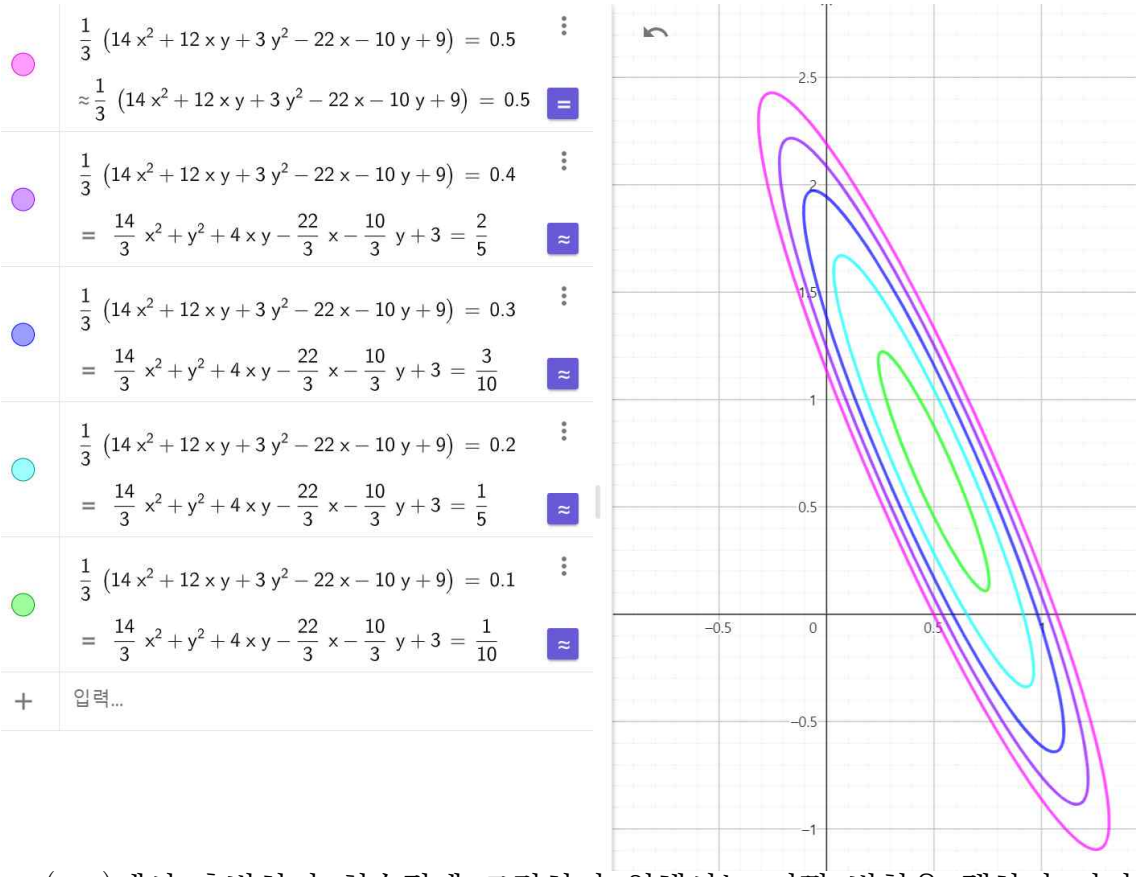
$$L(a,b)=\frac{1}{3}(14a^2+12ab+3b^2-22a-10b+9)$$

였다. a,b대신 문자 x,y를 써서

$$z=f(x,y)=\frac{1}{3}(14x^2+12xy+3y^2-22x-10y+9)$$

의 등고선을 표시해보면 다음과 같다.

이것으로 보아 손실함수의 그래프는 단면이 타원인 볼록함수임을 알 수 있다. 우리의 목적은 $L(a,b)$가 최소가 되는 (a,b)의 좌표, 즉 최솟점을 찾는 것이었다. 등고선 그림으로 미루어 보아 최솟점은 어디인가? 임의의 위치



(x,y)에서 출발하여 최솟점에 도달하기 위해서는 어떤 방향을 택하여 나아가야 하겠는가?

<이변수함수에서의 경사하강법>

이제 여러분이 예를 들어 $(x,y)=(0,0)$ 위치에 서 있다고 하자. 그리고 $z=x^2-y^2$의 등고선 그래프를 보고, 높이 z 가 -2인 곳으로 가장 짧은 거리로 내려가고 싶다면 여러분은 어느 경로를 따라 진행하겠는가? 반대로 $(x,y)=(2,0)$에 위치해 있다고 생각하고 높이 z가 0인 곳으로 가장 빨리 내려가고 싶다면 어떤 경로를 따라 이동하겠는가? 이것이 이변수함수에서의 최적화 과정이다. 등고선을 보아 우리는 각 지점에서 다음 등고선까지 거리가 가장 짧은 경로, 즉 매 순간 등고선 간 간격이 가장 작은 방향을 따라 내려오면 되고, 이는 매 지점에서 등고선과 **수직인 방향**을 택하면 되는 것으로 보인다. 그러나 $L(x,y)$ 함수의 경우를 살펴보면 매 순간 등고선에 수직인 방향으로 내려가는 것이 최솟점에 가장 빠르게 도달하는 경로는 아닌 것을 알 수 있다. 예를 들어 $(1/2,0)$ 위치에서 최솟점으로 향하는 가장 빠른 방향은 등고선에 수직인 방향이 아닌 y축에 평행한 방향임을 알 수 있

다. 등고선에 수직인 방향이 최솟점까지의 최단거리를 보장하지는 않지만, 매 순간 $f(x,y)$가 가장 빨리 감소하는 방향으로 나아가고 있는 것이고 따라서 함수 f가 아래로 볼록한 함수라면 결국에는 최솟점에 도달할 수 있다는 보장을 해준다. 즉, 최단거리는 아닐지라도 최저점에 결국에는 도달하게 되는 방향이다. 너무 큰 스텝을 잡으면 불필요하게 지그재그 경로로 이동하게 될 수도 있다. 수렴성을 보장하는 방향, 즉 각 지점에서 기울기가 음으로 가장 가파른 방향은 어떻게 계산할 수 있는가? 답은 기울기(경사도)의 계산에 있다. 이제 다변수 함수에서의 기울기 개념을 알아보자.

< 다변수함수의 편미분, 편도함수의 정의 >

이변수함수

$$z = f(x,y)$$

에서 y를 고정시켜, 이를 x만의 함수로 보고 x 에 관한 f 의 도함수

$$\lim_{\Delta x \to 0} \frac{f(x+\Delta x, y) - f(x,y)}{\Delta x}$$

가 존재할 때, 이를 x 에 관한 f 의 **편도함수**(partial derivative)라고 하고, 다음과 같은 기호로 나타낸다.

$$\frac{\partial f}{\partial x},\ \frac{\partial}{\partial x} f(x,y),\ f_x(x,y),\ \frac{\partial z}{\partial x},\ z_x$$

특정한 점 (a,b)에서의 편도함수의 값 $f_x(a,b)$ 를 x에 관한 (a,b)에서의 **편미분계수**라고 부른다. 마찬가지로 y에 관한 f의 편도함수를

$$\lim_{\Delta y \to 0} \frac{f(x, y+\Delta y) - f(x,y)}{\Delta y}$$

로 정의하며, 다음과 같은 기호로 나타낸다.

$$\frac{\partial f}{\partial y},\ \frac{\partial}{\partial y} f(x,y),\ f_y(x,y),\ \frac{\partial z}{\partial y},\ z_y$$

편도함수가 존재하면 **편미분가능하다**고 하고 편도함수를 구하는 일을 편미분한다고 한다.

예: $z = x^2y - y^3 - 5x + 2y - 1$에서

$$\frac{\partial z}{\partial x} = \lim_{h \to 0} \frac{\{(x+h)^2y - y^3 - 5(x+h) + 2y - 1\} - \{x^2y - y^3 - 5x + 2y - 1\}}{h}$$

$= 2xy - 5$

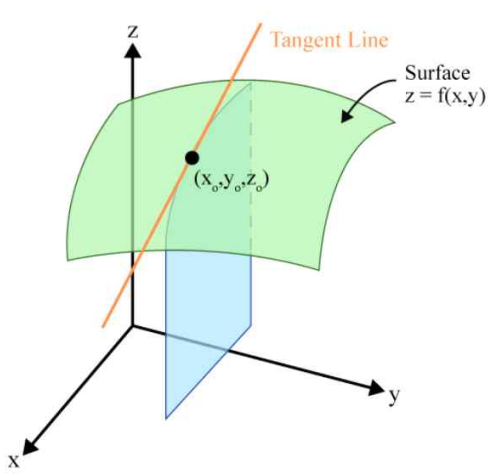
이고 이것은 y를 상수로 취급하고 x만에 대해서 미분한 것과 같다. x를 상수로 취급하고 y만에 대해서 미분을 하면 $\frac{\partial z}{\partial y} = x^2 - 3y^2 + 2$ 이다. 구체적으로 $(3,2)$에서의 x방향 변화율은 $\frac{\partial z}{\partial x}(3,2) = 2 \cdot 3 \cdot 2 - 5 = 7$이다. 즉 $(x,y) = (3,2)$에서 x축에 평행한 양의 방향으로 나아가면 (x값을 증가시키면) z의 값은 x값의 변화량에 7배 만큼 증가한다. 즉, $\Delta z \approx \frac{\partial z}{\partial x}\Delta x = 7 \times \Delta x$이다. 반면, $\frac{\partial z}{\partial x}(3,2) = -1$이므로 y축에 평행한 양의 방향으로 나아가면 (y값을 증가시키면) z의 값은 y값의 변화량에 1배 만큼 감소한다. 즉, $\Delta z \approx \frac{\partial z}{\partial x}\Delta x = (-1) \times \Delta y$이다. 그렇다면 점 $(3,2)$에서 어느 방향으로 나아가야 z의 값이 가장 빠르게 감소(또는 증가)하는 방향으로 나아갈 수 있을까?

예제: 점 $(4,-5)$ 에서 함수 $f(x,y) = x^2 + 3xy + y - 1$ 에 대하여 $\frac{\partial f}{\partial x}(4,-5)$의 값을 구하여라.

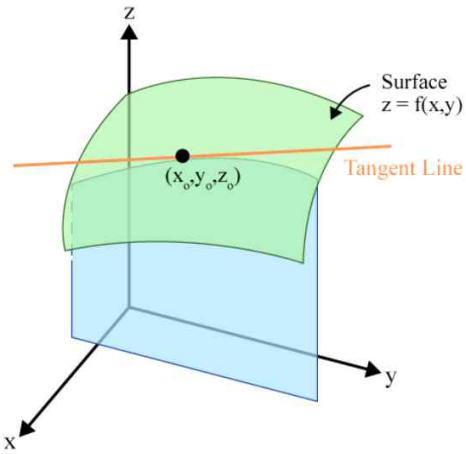
예제: 함수 $f(x,y) = y\sin xy$의 $\frac{\partial f}{\partial y}$를 구하여라. (힌트: $\sin x$의 미분은 $\cos x$이고 곱의 미분법과 합성함수 미분법을 사용한다.)

예제: $f(x,y) = e^{-x}\sin(x+2y)$에 대하여 $f_x\left(0,\frac{\pi}{4}\right)$, $f_y\left(0,\frac{\pi}{4}\right)$를 구하여라. (힌트: e^x의 미분은 e^x이다.

<편도함수의 기하학적 의미>



Slope of the surface in the x-direction



Slope of the surface in the y-direction

함수 $z=f(x,y)$의 그래프가 그림과 같은 곡면이라고 하고, 곡면 위의 한 점 $P(x_0,y_0,z_0)$를 지나 xz평면과 평행한 평면, 즉 $y=y_0$와 곡면이 만나는 교선을 생각하자. 이 교선 위의 점들의 좌표는 y의 값은 y_0로 고정되어 $(x,y_0,f(x,y_0))$이고 x의 값만 독립적으로 변하면서 그에 따라 높이 $z=f(x,y_0)$가 변하는 x에 대한 일변수함수의 그래프로 생각할 수 있다. (단면만 떼어서 그려보라). 그러면 $\frac{\partial z}{\partial x}(x_0,y_0)$는 이 교선에서 x축 방향으로의 변화율인 접선(Tangent line)의 기울기를 의미한다.

<극대, 극소점에서의 편미분계수>

$z=x^2+y^2$ 은 값은 z값이 항상 음이 아닌 실수이고, $(x,y)=(0,0)$에서 $z=0$이므로 $(0,0)$이 함수의 최솟점이 되며 최솟값은 0임이 자명하다. 또한 $\frac{\partial z}{\partial x}(0,0)=0=\frac{\partial z}{\partial y}(0,0)$ 임을 계산을 통해 알 수 있다. 편미분계수의 정의와 1변수함수가 극값을 가질 조건을 생각하면 당연하게도 미분가능한 극솟점에서 항상 $\frac{\partial z}{\partial x}=\frac{\partial z}{\partial y}=0$이다. 그러나 어떤 점 (a,b)에서 $\frac{\partial z}{\partial x}=\frac{\partial z}{\partial y}=0$ 이라고 해서 (a,b)가 극솟점인 것은 아니다. $z=x^2-y^2$

에서 안장점 $(0,0)$이 그 예이다.

만일 함수 $z=f(x,y)$가 볼록함수이고 따라서 유일한 극솟점이자 최솟점을 갖는다는 것을 알고 있다면, $f(x,y)$의 최솟점은 $\frac{\partial z}{\partial x}=0$, $\frac{\partial z}{\partial y}=0$ 을 만족하는 점 (a,b)를 연립방정식을 풀어서 구할 수 있다. 이렇듯 이변수함수의 최적화 문제는 함수가 볼록함수라면 편미분을 이용하여 어렵지 않게 풀 수 있다. 문제는 다변수함수 $z=f(x_1,x_2,\cdots,x_n)$의 경우에는 연립으로 풀어야 하는 방정식의 갯수가 n개가 되고, 흔히 인공지능에서 이 n는 수백조를 넘어서므로 단순히 편미분을 이용해서 "미분해서 0이 되는 점"을 한번에 찾는 것은 불가능하다. 이제 선형회귀에서 나타난 손실함수 $L(a,b)$의 최솟점을 찾을 수 있겠는가?

계속해서 편미분의 개념을 알아보자.

< 그래디언트(gradient) >

이변수함수 f에 대해서 f의 **그래디언트**(gradient)는 벡터 ∇f이며 다음과 같이 정의된다.

$$\nabla f(x,y)=\left(\frac{\partial f}{\partial x},\frac{\partial f}{\partial y}\right)$$

마찬가지로 다변수함수 f에 대해 f의 그래디언트는 다음과 같이 정의된다.

$$\nabla f(x_1,x_2,\cdots,x_n)=\left(\frac{\partial f}{\partial x_1},\cdots,\frac{\partial f}{\partial x_n}\right)$$

예: $f(x,y,z)=x^2+yz-2xy-z^2$이면

$$\nabla f(x,y,z)=(2x-2y,\ z-2x,\ y-2z)$$

이고, $\nabla f(2,1,3)=(2,-1,-5)$이다.

< 변화율과 변화 >

다시 미분계수의 정의로 돌아가자.

$$f'(a)=\lim_{\Delta x\to 0} f^{\Delta x}(a)=\lim_{\Delta x\to 0}\frac{\Delta y}{\Delta x}=\lim_{\Delta x\to 0}\frac{f(a+\Delta x)-f(a)}{\Delta x}$$

이제 아주 작은 Δx에 대해서

$$f'(a) \approx f^{\Delta x}(a) = \frac{f(a+\Delta x) - f(a)}{\Delta x}$$

이므로, $f(a+\Delta x) - f(a) = f^{\Delta x}(a)\Delta x$ 이고 따라서 $\Delta y \approx f'(a)\Delta x$ 이다. 즉,

$$y\text{의 변화} \approx (x\text{에 대한 } y\text{의 변화율}) \times x\text{의 변화}$$

로 변화율과 x의 변화량으로부터 y의 변화량을 예측할 수 있다. 이를 **선형근사**(linear approximation) 라고 한다.

예: $y = f(x) = x^2$ 이면 $f'(x) = 2x$ 이다. $f(1) = 1$이고 $f'(1) = 2$이다. 이제 $f(1.1) = 1.21$이므로 $\Delta x = 0.1$에 대한 $\Delta y = 0.21$ 이다. 한편, 근사 공식으로부터 $f'(1) \times \Delta x = 2 \times 0.1 = 0.2$ 이고 따라서 $f(1.1)$에 대한 근사공식을 이용한 예측값은 $1 + 0.2 = 1.2$이고 이것은 1.21과 비슷하다. 더 작은 Δx에 대해서 근사공식은 더 작은 오차로 함수값 $f(1+\Delta x)$ 값을 예측한다. 이것이 미분의 쓰임이다.

이변수함수 $z = f(x,y)$에 대해서도 이와 같은 공식이 있는데 이는 다음과 같다.

$$\Delta z \approx \frac{\partial z}{\partial x}\Delta x + \frac{\partial z}{\partial y}\Delta y$$

즉,

$$z\text{의 변화} \approx (x\text{에 대한 } z\text{의 변화율}) \times (x\text{ 변화량})$$
$$+ (y\text{에 대한 } z\text{의 변화율}) \times (y\text{ 변화량})$$

이다. 항이 하나 늘어났다. 독립변수가 하나 늘어났기 때문이다. 그래디언트와 벡터의 내적의 정의를 이용하면 이는

$$\Delta z \approx \nabla f(x_0, y_0) \cdot (\Delta x, \Delta y) = \nabla f(x_0, y_0) \cdot (x - x_0, y - y_0)$$

이다. 여기서 $\Delta x = x - x_0$, $\Delta y = y - y_0$이다.

내적의 기하학적 정의에서 $\nabla f \cdot (\Delta x, \Delta y) = |\nabla f| \times |(\Delta x, \Delta y)| \times cos\theta$이다. 여기서 θ는 두 벡터 ∇f와 $(\Delta x, \Delta y)$ 의 사잇각이다. 만약 주어진 점 (x_0, y_0)에서 길이를 1 만큼만, 즉 $|(\Delta x, \Delta y)| = 1$ 만큼만 이동하여야 한다면, $\nabla f \cdot (\Delta x, \Delta y) = |\nabla f| \times cos\theta$ 이다. ∇f 의 값은 (x_0, y_0) 점에 의해

정해지는 벡터(방향)이다. 따라서 z값이 가장 많이 증가하는 방향은 θ에 의해 결정되고, 이는 $\theta = 0$ 인 ∇f 방향이다. 반대로, $\theta = -180^o$인 $-\nabla f$ 방향이 z값이 가장 많이 감소하는 방향이다. 즉, 주어진 점 (x_0, y_0)에서 z값이 가장 빠르게 감소하는 방향은 **그래디언트의 반대방향**이다. 일변수 함수에서의 경사하강법과의 유사성을 생각해보자.

따라서 이변수 함수의 경사하강법을 다음과 같이 생각할 수 있다.

초깃값 $X_0 = (x_0, y_0)$에 대하여, $X_n = (x_n, y_n)$ 이라 하면

$$X_{n+1} = X_n - \alpha \nabla f(X_n),\ n = 0, 1, \cdots, n$$

으로 반복적으로 이동한다. 이때 α는 step size, 또는 학습률(learning rate) 이다.

함수 $z = f(x, y)$가 볼록함수인 경우, 경사하강법은 적당한 α에 대하여 유일한 최솟점 $X^* = \arg f(X)$에 수렴함이 알려져 있다. 단. 최단 경로는 아닐 수 있다.

일반적으로 다변수 함수

$z = f(x_1, x_2, \cdots, x_n)$에서 초깃값 $X_0 = (x_1^0, x_2^0, \cdots, x_n^0)$에 대하여,

$X_k = (x_1^k, x_2^k, \cdots, x_n^k)$ 이라 하면

$$X_{k+1} = X_k - \alpha \nabla f(X_k),\ k = 0, 1, \cdots,$$

으로 반복적으로 이동한다. 즉, $i = 1, 2, \cdots, n$ 에 대하여

$$x_i^{k+1} = x_i^k - \alpha \times \frac{\partial f}{\partial x_i}(X_k),\ k = 0, 1, 2, \cdots,$$

으로 각 독립변수 x_i를 업데이트한다.

이제 손실함수 $L(a, b)$의 최솟값을 경사하강법을 이용하여 찾을 수 있겠는가?