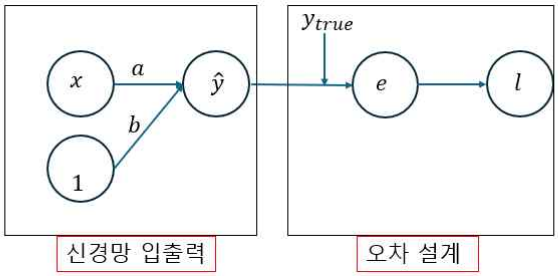
선형회귀에서의 경사하강법

훈련 데이터

x	y
x_1	y_1
x_2	y_2
...	...
x_N	y_N



$$\hat{y} = ax + b \quad e = \hat{y} - y_{true} \quad l = e^2$$

$$\frac{dl}{de} = 2e \quad \frac{\partial e}{\partial \hat{y}} = 1 \quad \frac{\partial \hat{y}}{\partial a} = x, \ \frac{\partial \hat{y}}{\partial b} = 1$$

$$\frac{\partial l}{\partial a} = \frac{dl}{de}\frac{de}{\partial \hat{y}}\frac{\partial \hat{y}}{\partial a} = 2e \cdot 1 \cdot x \qquad \frac{\partial l}{\partial b} = \frac{dl}{de}\frac{de}{\partial \hat{y}}\frac{\partial \hat{y}}{\partial b} = 2e \cdot 1 \cdot 1$$

$$\frac{\partial L}{\partial a} = \frac{1}{N}\sum_{i=1}^{N}\frac{\partial l}{\partial a} = \frac{1}{N}\sum_{i=1}^{N} 2e_i x_i \qquad \frac{\partial L}{\partial b} = \frac{1}{N}\sum_{i=1}^{N}\frac{\partial l}{\partial b} = \frac{1}{N}\sum_{i=1}^{N} 2e_i$$

데이터 $(x_1, y_1), \cdots (x_N, y_N)$이 주어졌을 때, 선형회귀식 $f(x) = ax + b$를 찾는 방법은 손실함수 $L(a,b) = \frac{1}{N}\sum_{i=1}^{N}(\hat{y_i} - y_i)^2$에 대해서 경사하강법을 적용하는 것이다.

여기서 변수 $\hat{y}$은 $\hat{y} = f(x) = ax + b$ 이다.

$\frac{\partial \hat{y}_i}{\partial a} = x$, $\frac{\partial \hat{y}_i}{\partial b} = 1$ 이므로 합성함수 미분법에 의해서

$$\begin{cases} \frac{\partial L}{\partial a} = \frac{1}{N}\sum_{i=1}^{N} 2(\hat{y}_i - y_i)x_i \\ \frac{\partial L}{\partial b} = \frac{1}{N}\sum_{i=1}^{N} 2(\hat{y}_i - y_i) \end{cases}$$

이다. 따라서 경사하강법 알고리즘을 적용하면

$$\begin{cases} a_{n+1} = a_n - \alpha\frac{\partial L}{\partial a} \\ b_{n+1} = b_n - \alpha\frac{\partial L}{\partial b} \end{cases}$$

와 같이 a, b값을 조금씩 변경시켜 가면서 L을 최소화 하는 a,b를 학습시킬 수 있다. 여기서 α는 학습률이다.

<오차역전파 알고리즘>

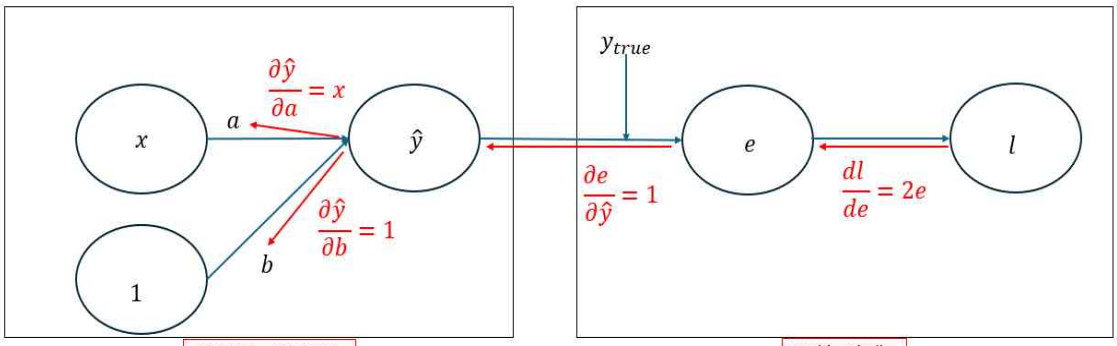
위에서 손실함수 L의 그래디언트 $\nabla L = (\frac{\partial L}{\partial a}, \frac{\partial L}{\partial b})$의 계산이 비교적 간단한 이유는 입력 x부터 출력 $\hat{y}$까지, 그리고 손실 l까지의 계산 구조가 $\hat{y} = ax + b$, $(\hat{y} - y)^2$로 매우 단순하기 때문이다. 그러나 실제 딥러닝에서는 입력부터 출력까지의 구조가 여러 함수의 반복적인 합성으로 되어있어 편미분을 계산하는 체계적인 계산 알고리즘이 필요하다. 뒤에서 다시 자세히 다루겠지만, 가장 단순한 모형인 선형회귀 문제를 통해 오차역전파법의 아이디어를 설명하고자 한다.

입력 x에서 손실 l까지의 계산을 구체적으로 따져보면서 순방향(왼쪽에서 오른쪽)으로의 흐름을 계산하고, 동시에 손실 l에서 매개변수 a와 b까지 역방향(오른쪽에서 왼쪽)으로의 변화율의 전파를 동시에 생각해 보자.

우선 각 단계별로 등장하는 변수들을 정의하자. 입력값 x에 대한 모델 함수 f의 출력을 $\hat{y} = f(x) = ax + b$라 하고, $\hat{y}$와 실제값 y와의 오차를 $e = \hat{y} - y$, 오차제곱손실을 $l = e^2$이라 하면 모든 데이터 (x_i, y_i)에 대한 손실함수 L은

$$L(a,b) = \frac{1}{N}\sum_{i=1}^{N} l_i, \qquad \begin{cases} \hat{y} = ax + b \\ e = \hat{y} - y \\ l = e^2 \end{cases} \quad \cdots (1)$$

이다. 때에 따라 아래첨자 i는 생략한다.



$$\hat{y} = ax + b$$
$$e = \hat{y} - y_{true}$$
$$l = e^2$$

$$\frac{dl}{de} = 2e, \quad \frac{\partial e}{\partial \hat{y}} = 1, \quad \frac{\partial \hat{y}}{\partial a} = x, \quad \frac{\partial \hat{y}}{\partial b} = 1$$

$$\frac{\partial l}{\partial a} = \frac{dl}{de}\frac{de}{\partial \hat{y}}\frac{\partial \hat{y}}{\partial a} = 2e \cdot 1 \cdot x$$
$$\frac{\partial l}{\partial b} = \frac{dl}{de}\frac{de}{\partial \hat{y}}\frac{\partial \hat{y}}{\partial b} = 2e \cdot 1 \cdot 1$$

$$\frac{\partial L}{\partial a} = \frac{1}{N}\sum_{i=1}^{N}\frac{\partial l}{\partial a} = \frac{1}{N}\sum_{i=1}^{N} 2e_i x_i$$
$$\frac{\partial L}{\partial b} = \frac{1}{N}\sum_{i=1}^{N}\frac{\partial l}{\partial b} = \frac{1}{N}\sum_{i=1}^{N} 2e_i$$

식 (1)에서 각 변수들 사이의 변화율을 구해보면,

$$\begin{cases} \dfrac{\partial l}{\partial e} = 2e \\ \dfrac{\partial e}{\partial \hat{y}} = 1 \\ \dfrac{\partial \hat{y}}{\partial a} = x, \quad \dfrac{\partial \hat{y}}{\partial b} = 1 \end{cases}$$

이고, 가중치 a와 b에 의존하는 모든 변수들의 상태를 추적하면서 합성함수 미분법을 적용하면

$$\begin{cases} \dfrac{\partial l}{\partial a} = \dfrac{\partial l}{\partial e}\dfrac{\partial e}{\partial \hat{y}}\dfrac{\partial \hat{y}}{\partial a} = 2e \cdot 1 \cdot x \\ \dfrac{\partial l}{\partial b} = \dfrac{\partial l}{\partial e}\dfrac{\partial e}{\partial \hat{y}}\dfrac{\partial \hat{y}}{\partial b} = 2e \cdot 1 \cdot 1 \end{cases}$$

이므로

$$\begin{cases} \dfrac{\partial L}{\partial a} = \dfrac{1}{N}\displaystyle\sum_{i=1}^{N}\dfrac{\partial l_i}{\partial a} = \dfrac{1}{N}\sum_{i=1}^{N} 2e_i \cdot x_i \\ \dfrac{\partial L}{\partial b} = \dfrac{1}{N}\displaystyle\sum_{i=1}^{N}\dfrac{\partial l_i}{\partial b} = \dfrac{1}{N}\sum_{i=1}^{N} 2e_i \end{cases}$$

으로 계산할 수 있다.

예를 들어

x	y
1	1
2	2
3	2

와 같이 데이터가 주어지고 $a_0 = 1, b_0 = 1$에서 시작하여 편미분 $\dfrac{\partial L}{\partial a}(a_0, b_0)$, $\dfrac{\partial L}{\partial b}(a_0, b_0)$를 계산하는 알고리즘을 생각해보자. $\hat{y} = x + 1$인 상태이므로,

- $x_1 = 1, y_1 = 1$:

$$\begin{cases} \hat{\mathrm{y}} = 2 \\ \mathrm{e} = 1 \\ \mathrm{l} = 1 \end{cases}, \quad \begin{cases} \dfrac{\mathrm{dl}}{\mathrm{de}} = 2 \\ \dfrac{\partial \mathrm{e}}{\partial \hat{\mathrm{y}}} = 1 \\ \dfrac{\partial \hat{\mathrm{y}}}{\partial \mathrm{a}} = 1, \dfrac{\partial \hat{\mathrm{y}}}{\partial \mathrm{b}} = 1 \end{cases}, \quad \begin{cases} \dfrac{\partial l}{\partial a} = 2 \\ \dfrac{\partial l}{\partial b} = 2 \end{cases},$$

• $x_2 = 2, y_2 = 2$:

$$\begin{cases} \hat{\mathrm{y}} = 3 \\ \mathrm{e} = 1 \\ \mathrm{l} = 1 \end{cases}, \quad \begin{cases} \dfrac{\mathrm{dl}}{\mathrm{de}} = 2 \\ \dfrac{\partial \mathrm{e}}{\partial \hat{\mathrm{y}}} = 1 \\ \dfrac{\partial \hat{\mathrm{y}}}{\partial \mathrm{a}} = 2, \dfrac{\partial \hat{\mathrm{y}}}{\partial \mathrm{b}} = 1 \end{cases}, \quad \begin{cases} \dfrac{\partial l}{\partial a} = 2 \cdot 1 \cdot 2 = 4 \\ \dfrac{\partial l}{\partial b} = 2 \cdot 1 \cdot 1 = 2 \end{cases}$$

• $x_2 = 3, y_2 = 2$:

$$\begin{cases} \hat{\mathrm{y}} = 4 \\ \mathrm{e} = 2 \\ \mathrm{l} = 4 \end{cases}, \quad \begin{cases} \dfrac{\mathrm{dl}}{\mathrm{de}} = 4 \\ \dfrac{\partial \mathrm{e}}{\partial \hat{\mathrm{y}}} = 1 \\ \dfrac{\partial \hat{\mathrm{y}}}{\partial \mathrm{a}} = 3, \dfrac{\partial \hat{\mathrm{y}}}{\partial \mathrm{b}} = 1 \end{cases}, \quad \begin{cases} \dfrac{\partial l}{\partial a} = 4 \cdot 1 \cdot 3 = 12 \\ \dfrac{\partial l}{\partial b} = 4 \cdot 1 \cdot 1 = 4 \end{cases}$$

이므로, $\dfrac{\partial L}{\partial a} = \dfrac{1}{3}(2+4+12) = \dfrac{18}{3}$, $\dfrac{\partial L}{\partial a} = \dfrac{1}{3}(2+2+4) = \dfrac{8}{3}$이다.

$\alpha = 0.03$으로 경사하강법을 한 번 적용하면,

$a_1 = 1 - 0.03 \times \dfrac{18}{3} = 0.82$, $b_1 = 1 - 0.03 \times \dfrac{8}{3} = 0.92$과 같다.