은닉층을 포함한 1차원 신경망으로 함수 근사하기
- Universarial approximation theorem

은닉층이 있는 인공신경망을 훈련하는 **오차역전파 알고리즘(backpropatation algorithm)**은 1986년 제프리 힌턴과 러멜하트, 윌리엄스의 논문에서 발표되면서 심층신경망(deep neural networks)은 다시금 큰 주목을 받게 되었다. 심층신경망은 은닉층(hidden layer)이 하나 이상인 인공신경망을 의미하며, 그 이전까지는 이러한 심층구조의 신경망을 효율적으로 훈련시키는 방법을 알지 못했기 때문에 활용 가치 역시 제대로 인식되지 못했다. 제프리 힌턴은 오랜 연구 끝에, 오차역전파 알고리즘을 체계화하였고, 이것이 당시 오랫동안 침체되어있던 인공지능 연구 분야에 새로운 활력을 불어넣는 계기가 되었다. 이후 1988년, 조지 시벤코는 심층신경망으로 무엇을 할 수 있고, 무엇을 할 수 없는지를 수학적으로 분석한 내용을 논문으로 발표하였으며, 이 논문은 보편근사정리(universarial approximation theorem)로 잘 알려져 있다. 그 주요 내용은 다음과 같다:

모든 연속함수는 하나 이상의 은닉층을 가진 인공신경망을 이용하여 임의의 정확도로 근사할 수 있다.

이는 "은닉층이 하나만 있어도 충분한 수의 뉴런이 있다면, 신경망은 모든 연속 함수를 임의의 정확도로 근사할 수 있다."는 의미이다. 따라서, 일변수 연속함수 $f(x)$는 비선형 함수 h의 선형 결합으로 얼마든지 가까이 근사할 수 있으며, 이는 다음과 같은 보편근사정리의 핵심 예가 된다:

$$f(x) \approx \sum_{i=1}^{N} w_i^{(2)} h(w_i^{(1)} x + b_i^{(1)}) + b^{(2)}$$

즉, 선형함수 $a(x) = wx + b$와 하나의 비선형 함수 $h(x)$의 합성함수 $(h \circ a)(x) = h(a(x)) = h(wx + b)$ 꼴을 연속적으로 선형 결합하여 $f(x)$를 근사할 수 있다는 것이다. 여기에서는 비선형 함수 $h(x)$으로 로지스틱함수 $h(x) = \dfrac{1}{1+e^{-x}}$ 를 사용하자.

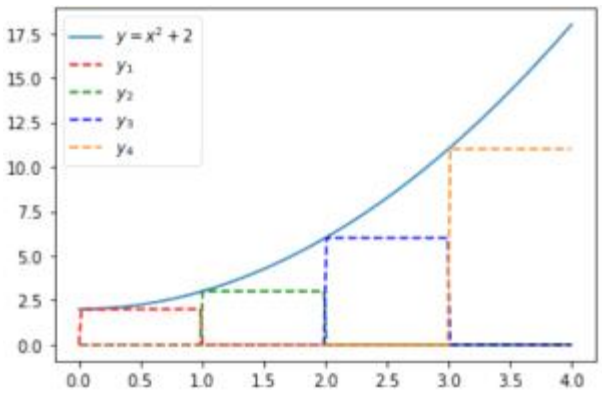


그림 1

그림 1과 같이 연속함수 $f(x) = x^2 + 2$를 네 개의 직사각형 모양의 함수들, y_1, y_2, y_3, y_n 합으로 근사할 수 있다. 즉 $n = 4$으로 $f(x) \approx y_1(x) + y_2(x) + y_3(x) + y_4(x)$으로 근사한 것이다. 직사각함수의 밑변의 길이를 짧게 하여 함수 y_i의 개수를 늘릴수록, 즉 $n \to \infty$ 일수록 $f(x)$를 더욱 가깝게 근사할 수 있다.

함수 $y_1 = y_1(x)$만 따로 생각해 보면 아래와 같이 두 개의 $h(wx+b)$꼴의 함수의 결합으로 표현할 수 있다. 단위사각함수

$$z_1(x) = h(100x) = \frac{1}{1+e^{-100x}},$$

$$z_2(x) = h(100x-100) = \frac{1}{1+e^{-(100x+100)}}$$

$$z_4(x) = h(100x-300)$$

$$z_3(x) = h(100x-200)$$

를 가지고 y_1을 근사해보자. 그림 2에 z_1과 $-z_2$를 -·-·-· 선으로 표시하였다.

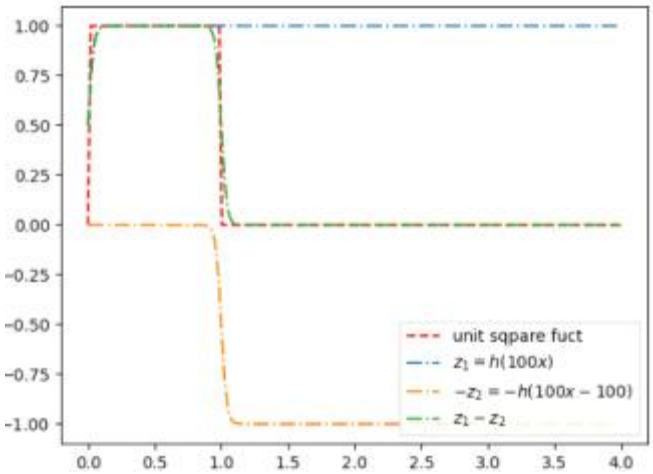


그림 2

이때 y_1은 단위사각함수(빨강)의 두 배이고, 단위사각함수는 $z_1 - z_2$로 근사할 수 있으므로 $y_1 \approx 2z_1 + (-2)z_2$ 으로 근사할 수 있다. 여기에서 x에 곱해지는 계수가 커질수록 시그모이드 함수의 경사가 커지며, 더 정확한 근사를 얻을 수 있다. 즉 임의의 연속함수는 직사각함수의 선형결합으로 근사할 수 있고, 직사각함수는 다시 두 개의 시그모이드 함수로 근사할 수 있으므로, 임의의 연속함수는 시그모이드 함수의 결합으로 표현할 수 있다. 구체적으로,

$$y_1 \approx 2z_1(x) - 2z_2(x)$$

$$y_2 \approx 3z_2(x) - 3z_3(x)$$

$$y_3 \approx 6z_3(x) - 6z_4(x)$$

$$y_4 = 11z_4(x)$$

이다. (여기서 $f(0) = 2, f(1) = 3, f(2) = 6, f(3) = 11$ 임을 이용했다.) 정리하자면,

$$f(x) \approx y_1 + y_2 + y_3 + y_4 \approx 2z_1 + z_2 + 3z_3 + 5z_4$$

로 근사할 수 있다. 코드는 보편근사정리 코드를 참고하라.

앞에서 살펴본 과정을 인공신경망의 도식으로 나타내면 그림 3과 같다. 그림에서 x와 y는 입력과 출력 노드이고, 하나의 은닉층을 포함하는 인공신경망이다. 큰 원은 은닉층의 하나의 노드를 나타내며 노드 안에서 활성화 함수 h의 작용을 화살표로 표시하였다. 즉, 각 은닉층 노드에서 $z = h(a)$이다. 이제 각 입력 x에 대한 변수들의 값은 다음과 같이 일차함수와 비선형함수 h의 반복적인 합성이다.

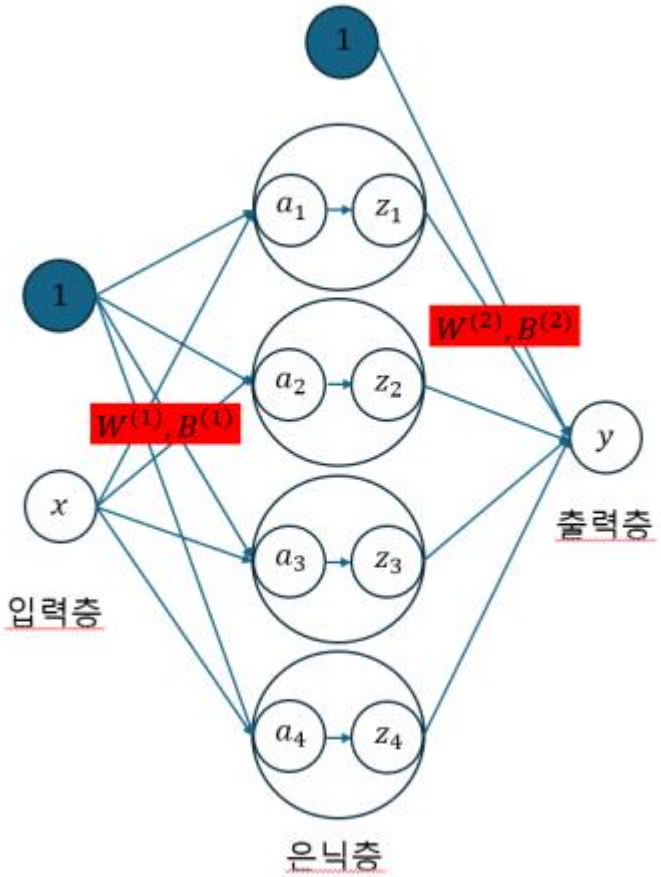


그림 3

$$\begin{cases} a_1 = xw_1^{(1)} + b_1^{(1)} \\ a_2 = xw_2^{(1)} + b_2^{(1)} \\ a_3 = xw_3^{(1)} + b_3^{(1)} \\ a_4 = xw_4^{(1)} + b_4^{(1)} \end{cases}, \quad \begin{cases} z_1 = h(a_1) \\ z_2 = h(a_2) \\ z_3 = h(a_3) \\ z_4 = h(a_4) \end{cases},$$

$$y = z_1 w_1^{(2)} + z_2 w_2^{(2)} + z_3 w_3^{(2)} + z_4 w_4^{(2)} + b^{(2)},$$

가중치와 편이를 행렬로

$$W_{1\times 4}^{(1)} = \left(w_1^{(1)}, w_2^{(1)}, w_3^{(1)}, w_4^{(1)}\right), \\ = (100, 100, 100, 100)$$

$$B_{1\times 4}^{(1)} = \left(b_1^{(1)}, b_2^{(1)}, b_3^{(1)}, b_4^{(1)}\right) \\ = (0, -100, -200, -300)$$

$$W^{(2)}_{4\times 1} = \begin{pmatrix} w^{(2)}_1 \\ w^{(2)}_2 \\ w^{(2)}_3 \\ w^{(2)}_4 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \\ 3 \\ 5 \end{pmatrix}, B^{(1)}_{1\times 1} = \left(b^{(1)}_1\right) = 0$$

라 하고, 은닉층의 변수를

$$A_{1\times 4} = (a_1, a_2, a_3, a_4),\ Z_{1\times 4} = (z_1, z_2, z_3, z_4)$$

로 표기하면, 행렬곱을 사용하여 간단히 나타낼 수 있다. 즉

$$A = (x)_{1\times 1} W^{(1)} + B^{(1)} = (x)_{1\times 1} (w^{(1)}_1, w^{(1)}_2, w^{(1)}_3, w^{(1)}_4) + \left(b^{(2)}_1, b^{(2)}_2, b^{(2)}_3, b^{(2)}_4\right),$$

$$Z = h(A) = (h(a^{(2)}_1), h(a^{(2)}_2), h(a^{(2)}_3), h(a^{(2)}_4))$$

$$y = ZW^{(2)} + B^{(2)} = \left(z_1, z_2, z_3, z_4\right) \begin{pmatrix} w^{(2)}_1 \\ w^{(2)}_2 \\ w^{(2)}_3 \\ w^{(2)}_4 \end{pmatrix} + b^{(2)}$$ 이다.

여기에서는 **은닉층이 한 층**이고 **은닉층에 노드를 네 개**로 설정했으나, 더 정확한 근사를 하기 위해서는 은닉층 노드의 개수(세로)를 충분히 늘리던지 은닉층의 층 수(가로)를 늘려야 한다.

은닉층을 사용한 1차원 분류

i	x	t
0	-2	0
1	-1	0
2	0	1
3	1	1
4	2	1
5	3	1
6	4	0
7	5	0

표 1

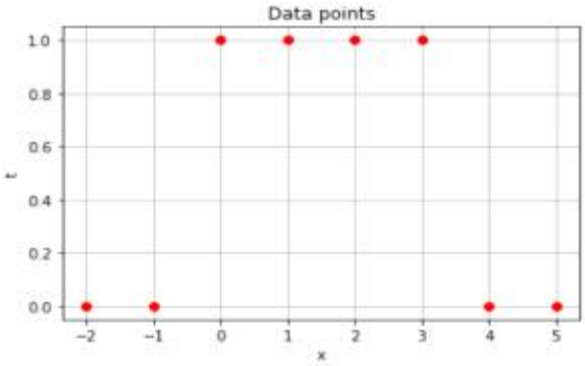


표 1과 같이 데이터가 주어졌다고 하자. 즉, $\{(x_i, y_i)\}, (i = 0,1,2,\cdots,7)$이며 데이터의 개수 $N = 8$이다. 은닉층을 한 겹으로 하고 노드는 두 개로 설정하면 될 것 같다(*왜?*). 신경망을 구성하고, 손실함수를 정의하고, 경사하강법을 사용하여 최적의 파라미터를 찾는 과정을 살펴보자.

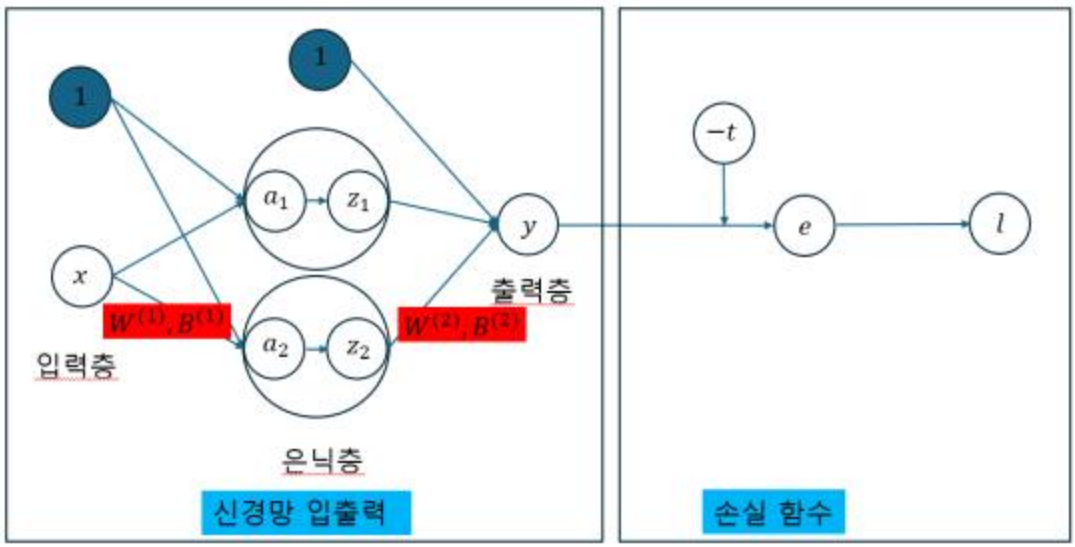


그림 5

- **신경망 구성하기**

그림 5의 노드에 나타나는 변수들에 대하여, 왼쪽에서 오른쪽으로의 값의 순전파를 계산해 보면,

$$\begin{cases} a_1 = xw_1^{(1)} + b_1^{(1)} \\ a_2 = xw_2^{(1)} + b_2^{(1)} \end{cases}, \quad \begin{cases} z_1 = h(a_1) \\ z_2 = h(a_2) \end{cases}, \quad y = z_1 w_1^{(2)} + z_2 w_2^{(2)} + b^{(2)}$$

이다. 즉, 신경망이 나타내는 함수는

$$y = w_1^{(2)} h(w_1^{(1)} x + b_1^{(1)}) + w_2^{(2)} h(w_2^{(1)} x + b_2^{(1)}) + b_1^{(2)}$$

이고 우리가 정해야 할 가중치와 편이는 총 7개 이다. 행렬을 이용하여 나타내보자. 가중치와 편이를

$$W_{1\times 2}^{(1)} = \left(w_1^{(1)}, w_2^{(1)}\right), \quad B_{1\times 2}^{(1)} = \left(b_1^{(1)}, b_2^{(1)}\right), \quad W_{2\times 1}^{(2)} = \begin{pmatrix} w_1^{(2)} \\ w_2^{(2)} \end{pmatrix}, \quad B_{1\times 1}^{(2)} = \left(b^{(2)}\right)$$

로 나타내고, 은닉층의 변수를

$$A = (a_1, a_2),\ Z = (z_1, z_2),$$

로 정의하면, 신경망은 다음과 같은 단계를 따라 출력 y를 계산한다.

$$A = (x)_{1\times 1} W^{(1)} + B^{(1)},\ Z = h(A),\ y = ZW^{(2)} + B^{(2)}$$

- **손실함수 정의하기**

신경망의 출력 y와 실제 데이터 t의 차이, 오차를 $e = y - t$이라 정의하고 제곱 오차를 $l = e^2$이라 하자. 평균제곱 손실함수(MSE)는

$$L(W^{(1)}, B^{(1)}, W^{(2)}, B^{(2)}) = \frac{1}{N}\sum_{i=0}^{N-1} l_i$$

으로 정의된다. 즉, 데이터가 주어졌을 때 L은 7변수 함수이다.

- **경사하강법을 사용하여 최적의 파라미터 찾기**

우리의 목적은 경사하강법을 이용하여 손실함수를 최소화하는 가중치와 편향 행렬 $W^{(1)}, B^{(1)}, W^{(2)}, B^{(2)}$를 찾는 것이다. 손실의 가중치와 편향 행렬에 대한 편미분(그래디언트)

$$\frac{\partial l}{\partial W^{(1)}} = \begin{pmatrix} \frac{\partial l}{\partial w_1^{(1)}} & \frac{\partial l}{\partial w_2^{(1)}} \end{pmatrix}_{1\times 2},\ \frac{\partial l}{\partial B^{(1)}} = \begin{pmatrix} \frac{\partial l}{\partial b_1^{(1)}} & \frac{\partial l}{\partial b_2^{(1)}} \end{pmatrix}_{1\times 2},$$

$$\frac{\partial l}{\partial W^{(2)}} = \begin{pmatrix} \frac{\partial l}{\partial w_1^{(2)}} \\ \frac{\partial l}{\partial w_2^{(2)}} \end{pmatrix}_{2\times 1},\ \text{그리고}\ \frac{\partial l}{\partial B^{(2)}} = \frac{\partial l}{\partial b^{(2)}}$$

를 찾아야 한다. 손실 l의 가중치와 편향에 대한 **그래디언트 행렬**의 크기를 가중치와 편향과 같게 **정의**한 것을 주목하여라.

그래디언트를 구하기 위해 변화율의 오른쪽에서 왼쪽으로의 역전파를 구하는데, 먼저 순전파를 계산하여 변수 A, Z, y, e, l의 값을 저장해 두고, 이 변수들로 그래디언트를 거꾸로 계산해 내는 것이 오차역전파 알고리즘이다. (모든 것은 합성함수 미분법이다.)

① 변수 l의 e에 대한 변화율: $\frac{\partial l}{\partial e} = 2e$

② 변수 l의 y에 대한 변화율: $\frac{\partial l}{\partial y} = \frac{\partial e}{\partial y}\frac{\partial l}{\partial e} = \frac{\partial l}{\partial e}$

③ 다음으로 $W^{(2)}$, $B^{(2)}$와 손실 l과의 연결을 추적해 보면,

$$\frac{\partial l}{\partial W^{(2)}} = \begin{pmatrix} \frac{\partial l}{\partial w_1^{(2)}} \\ \frac{\partial l}{\partial w_2^{(2)}} \end{pmatrix}_{2\times 1} = \begin{pmatrix} \frac{\partial y}{\partial w_1^{(2)}} \cdot \frac{\partial l}{\partial y} \\ \frac{\partial y}{\partial w_1^{(2)}} \cdot \frac{\partial l}{\partial y} \end{pmatrix}_{2\times 1} = \begin{pmatrix} \frac{\partial y}{\partial w_1^{(2)}} \\ \frac{\partial y}{\partial w_1^{(2)}} \end{pmatrix}_{2\times 1} \left(\frac{\partial l}{\partial y}\right)_{1\times 1}$$

$$= \begin{pmatrix} z_1 \\ z_2 \end{pmatrix}_{2\times 1} \left(\frac{\partial l}{\partial y}\right)_{1\times 1}$$

$$= Z^T{}_{2\times 1} \left(\frac{\partial l}{\partial y}\right)_{1\times 1}$$

$$\frac{\partial l}{\partial B^{(2)}} = \frac{\partial l}{\partial b^{(2)}} = \frac{\partial y}{\partial b^{(2)}} \frac{\partial l}{\partial y} = \frac{\partial l}{\partial y}$$

④ 다음으로, 중간 단계 Z와 A에 대한 변화율을 계산하면,

$$\frac{\partial l}{\partial Z} = \begin{pmatrix} \frac{\partial l}{\partial z_1} & \frac{\partial l}{\partial z_2} \end{pmatrix}_{1\times 2} = \begin{pmatrix} \frac{\partial y}{\partial z_1}\frac{\partial l}{\partial y} & \frac{\partial y}{\partial z_2}\frac{\partial l}{\partial y} \end{pmatrix}_{1\times 2} = \begin{pmatrix} w_1^{(2)}\frac{\partial l}{\partial y} & w_2^{(2)}\frac{\partial l}{\partial y} \end{pmatrix}_{1\times 2}$$

$$= \left(\frac{\partial l}{\partial y}\right)_{1\times 1} \begin{pmatrix} w_1^{(2)} & w_2^{(2)} \end{pmatrix}_{1\times 2} = \left(\frac{\partial l}{\partial y}\right)_{1\times 1} W^{(2)^T}$$

$$\frac{\partial l}{\partial A} = \begin{pmatrix} \frac{\partial l}{\partial a_1} & \frac{\partial l}{\partial a_2} \end{pmatrix}_{1\times 2} = \begin{pmatrix} \frac{\partial z_1}{\partial a_1}\frac{\partial l}{\partial z_1} & \frac{\partial z_2}{\partial a_2}\frac{\partial l}{\partial z_2} \end{pmatrix}_{1\times 2}$$

$$= \begin{pmatrix} z_1(1-z_1) & z_2(1-z_2) \end{pmatrix} @ \begin{pmatrix} \frac{\partial l}{\partial z_1} & \frac{\partial l}{\partial z_2} \end{pmatrix}$$

$$= Z @ (1-Z) @ \frac{\partial l}{\partial Z}$$

여기서 연산 @는 같은 자리에 있는 성분끼리의 곱을 의미한다(이러한 연산을 Hadamard 곱이라고 한다. 이는 행렬곱과도 다르고 내적과도 다르며 그저 식을 단순화 하기 위한 기호이다.) $1-Z$에서 1은 벡터 $(1\ 1)$을 나타낸다.

⑤ 마지막으로 $W^{(1)}$과 $B^{(1)}$에 대한 변화율을 계산하면,

$$\frac{\partial l}{\partial W^{(1)}} = \begin{pmatrix} \frac{\partial l}{\partial w_1^{(1)}} & \frac{\partial l}{\partial w_2^{(1)}} \end{pmatrix}_{1\times 2} = \begin{pmatrix} \frac{\partial a_1}{\partial w_1^{(1)}}\frac{\partial l}{\partial a_1} & \frac{\partial a_2}{\partial w_2^{(1)}}\frac{\partial l}{\partial a_2} \end{pmatrix}_{1\times 2}$$

$$= \begin{pmatrix} x\frac{\partial l}{\partial a_1} & x\frac{\partial l}{\partial a_2} \end{pmatrix} = (x)_{1\times 1} \begin{pmatrix} \frac{\partial l}{\partial a_1} & \frac{\partial l}{\partial a_2} \end{pmatrix}_{1\times 2}$$

$$= (x)_{1\times 2} \frac{\partial l}{\partial A}$$

$$\frac{\partial l}{\partial B^{(1)}} = \left(\frac{\partial l}{\partial b_1^{(1)}} \ \frac{\partial l}{\partial b_2^{(1)}} \right)_{1\times 2} = \left(\frac{\partial a_1}{\partial b_1^{(1)}} \frac{\partial l}{\partial a_1} \ \frac{\partial a_2}{\partial b_2^{(1)}} \frac{\partial l}{\partial a_2} \right)_{1\times 2}$$
$$= \left(\frac{\partial l}{\partial a_1} \ \frac{\partial l}{\partial a_2} \right)$$
$$= \frac{\partial l}{\partial A}$$

⑥ 추가적으로 입력 변수 x에 대한 미분까지 살펴보면

$$\frac{\partial l}{\partial x} = \frac{\partial a_1}{\partial x}\frac{\partial l}{\partial a_1} + \frac{\partial a_2}{\partial x}\frac{\partial l}{\partial a_2}$$
$$= w_1^{(1)}\frac{\partial l}{\partial a_1} + w_2^{(1)}\frac{\partial l}{\partial a_2}$$
$$= \left(\frac{\partial l}{\partial a_1} \frac{\partial l}{\partial a_2} \right) \begin{pmatrix} w_1^{(1)} \\ w_2^{(1)} \end{pmatrix}$$
$$= \frac{\partial l}{\partial A} W^{(1)^T}$$

이제 ①~⑥를 정리하면

$$\frac{\partial l}{\partial e} = 2e$$
$$\frac{\partial l}{\partial y} = \frac{\partial l}{\partial e}$$
$$\frac{\partial l}{\partial W^{(2)}} = Z^T \frac{\partial l}{\partial y}, \quad \frac{\partial l}{\partial B^{(2)}} = \frac{\partial l}{\partial y}$$
$$\frac{\partial l}{\partial Z} = \left(\frac{\partial l}{\partial y} \right)_{1\times 1} W^{(2)^T}, \ \frac{\partial l}{\partial A} = Z @ (1 - Z) @ \frac{\partial l}{\partial Z}$$

$$\frac{\partial l}{\partial W^{(1)}} = (x)_{1\times 2} \frac{\partial l}{\partial A}, \quad \frac{\partial l}{\partial B^{(1)}} = \frac{\partial l}{\partial A}$$
$$\frac{\partial l}{\partial x} = \frac{\partial l}{\partial A} W^{(1)^T}$$

과 같이 단계적으로 계산할 수 있다. 여기서 주목할 점은, 우에서 좌로 이전 단계까지 전파된 오차의 변화율이 다음 단계에서 오차의 변화율에 사용된다는 것이다. 마치 오차가 우에서 좌로 흐르는 것 같이 생각될 수 있다.

이제 최적화가 수행되기 전의 파라미터인 $W_0^{(1)}, B_0^{(1)}, W_0^{(2)}, B_0^{(2)}$에서 시작하여 아래와 같이 경사하강법을 반복적으로 적용하여 데이터를 더 잘 표현할 수 있는 파라미터를 찾아간다.

$$
\begin{cases}
W_{k+1}^{(1)} = W_k^{(1)} - \alpha \dfrac{\partial L}{\partial W_k^{(1)}} = W_k^{(1)} - \alpha \dfrac{1}{N} \displaystyle\sum_{i=0}^{N-1} \dfrac{\partial l_i}{\partial W_k^{(1)}} \\
B_{k+1}^{(1)} = B_k^{(1)} - \alpha \dfrac{\partial L}{\partial B_k^{(1)}} = B_k^{(1)} - \alpha \dfrac{1}{N} \displaystyle\sum_{i=0}^{N-1} \dfrac{\partial l_i}{\partial B_k^{(1)}} \\
W_{k+1}^{(2)} = W_k^{(2)} - \alpha \dfrac{\partial L}{\partial W_k^{(2)}} = W_k^{(2)} - \alpha \dfrac{1}{N} \displaystyle\sum_{i=0}^{N-1} \dfrac{\partial l_i}{\partial W_k^{(2)}} \\
B_{k+1}^{(2)} = B_k^{(2)} - \alpha \dfrac{\partial L}{\partial B_k^{(2)}} = B_k^{(2)} - \alpha \dfrac{1}{N} \displaystyle\sum_{i=0}^{N-1} \dfrac{\partial l_i}{\partial B_k^{(2)}}
\end{cases}
, \ k = 0, 1, 2, \cdots, epochs
$$

(여기서 α는 학습률이고, $\dfrac{1}{N}$은 α에 흡수하여 생략할 수 있다.)

여기까지 살펴본 과정을 구현한 코드는 2층 2노드 분류 신경망 에서 확인할 수 있다. 코드를 활용하여 데이터와 노드의 개수를 변경하면서 다양한 실험을 해볼수 있다. 아래는 실험 결과의 예시이다.

