중간고사 정답 및 풀이

딥러닝개론및연습 · 2026년 2학기

1. $q = x + y$, $p = xy$, $f = qp$로 정의된 계산 그래프를 생각하자.

(a) 계산 그래프를 그리고, $(x, y) = (1, 2)$에서 순전파로 q, p, f를 구하라.

(b) 각 연결의 local derivative를 쓰고, 역전파로 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$를 구하라. x에서 화살표가 두 개 나가는 것에 주의하라.

풀이

(a) 계산 그래프: $x, y \to q = x + y$, $x, y \to p = xy$, $q, p \to f = qp$ (x와 y에서 화살표가 두 개씩 나간다). 순전파: $q = 3$, $p = 2$, $f = 6$.

(b) local derivative: $\frac{\partial f}{\partial q} = p = 2$, $\frac{\partial f}{\partial p} = q = 3$, $\frac{\partial q}{\partial x} = \frac{\partial q}{\partial y} = 1$, $\frac{\partial p}{\partial x} = y = 2$, $\frac{\partial p}{\partial y} = x = 1$. x에서 나가는 두 경로의 기여를 더한다.

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial q}\frac{\partial q}{\partial x} + \frac{\partial f}{\partial p}\frac{\partial p}{\partial x} = 2\cdot 1 + 3\cdot 2 = 8, \qquad \frac{\partial f}{\partial y} = \frac{\partial f}{\partial q}\frac{\partial q}{\partial y} + \frac{\partial f}{\partial p}\frac{\partial p}{\partial y} = 2\cdot 1 + 3\cdot 1 = 5$$

(검산: $f = (x + y)xy = x^2y + xy^2$이므로 $f_x = 2xy + y^2 = 8$, $f_y = x^2 + 2xy = 5$.)

2. $f(x, y) = x^4 + xy + y^2$에 대하여 $(x_0, y_0) = (1, 0)$에서 Newton step을 계산하라. 즉 $\boldsymbol{g}_0 = \nabla f(1, 0)$, $H_0 = H(1, 0)$를 구하고 연립방정식 $H_0\boldsymbol{p}_0 = -\boldsymbol{g}_0$를 풀어 (x_1, y_1)을 구하라.

풀이

$\nabla f = (4x^3 + y,\ x + 2y)$, $H = \begin{pmatrix} 12x^2 & 1 \\ 1 & 2 \end{pmatrix}$이므로

$$\boldsymbol{g}_0 = (4,\ 1), \qquad H_0 = \begin{pmatrix} 12 & 1 \\ 1 & 2 \end{pmatrix}, \qquad \det H_0 = 23.$$

$H_0\boldsymbol{p}_0 = -\boldsymbol{g}_0$, 즉 $12p_1 + p_2 = -4$, $p_1 + 2p_2 = -1$을 풀면

$$\boldsymbol{p}_0 = \left(-\frac{7}{23}, -\frac{8}{23}\right) \approx (-0.304,\ -0.348), \qquad (x_1, y_1) = \left(\frac{16}{23}, -\frac{8}{23}\right) \approx (0.696,\ -0.348).$$

(검산: $12 \cdot (-\frac{7}{23}) - \frac{8}{23} = -4$, $-\frac{7}{23} + 2 \cdot (-\frac{8}{23}) = -1$.)

3. 활성화 함수의 미분에 관한 문제이다.

(a) $\sigma(a) = \dfrac{1}{1 + e^{-a}}$에 대하여 $\sigma'(a) = \sigma(a)\big(1 - \sigma(a)\big)$임을 보이고, $\sigma'(a)$의 최댓값과 그때의 a를 구하라.

(b) $\tanh(a) = 2\sigma(2a) - 1$임을 보이고, $\tanh'(a) = 1 - \tanh^2(a)$를 유도하라.

(c) ReLU $h(a) = \max(0, a)$의 도함수를 쓰라. 역전파에서 ReLU 계층은 gradient를 어떻게 전달하는가?

(d) (a)의 결과를 이용하여, sigmoid를 쓰는 층을 여러 개 쌓으면 역전파에서 gradient가 작아지는 이유를 설명하라.

풀이

(a) $\sigma'(a) = \dfrac{e^{-a}}{(1+e^{-a})^2} = \dfrac{1}{1+e^{-a}} \cdot \dfrac{e^{-a}}{1+e^{-a}} = \sigma(a)\big(1-\sigma(a)\big)$. $\sigma(1-\sigma) = \frac{1}{4} - \big(\sigma - \frac{1}{2}\big)^2 \le \frac{1}{4}$ 이고 등호는 $\sigma(a) = \frac{1}{2}$, 즉 $a = 0$ 일 때이다. 최댓값은 $\frac{1}{4}$ $(a = 0)$.

(b) $2\sigma(2a) - 1 = \dfrac{2}{1+e^{-2a}} - 1 = \dfrac{1-e^{-2a}}{1+e^{-2a}} = \dfrac{e^{a}-e^{-a}}{e^{a}+e^{-a}} = \tanh(a)$. 따라서 $\tanh'(a) = 4\sigma'(2a) = 4\sigma(2a)\big(1-\sigma(2a)\big)$ 이고, $\sigma(2a) = \frac{1+\tanh a}{2}$, $1-\sigma(2a) = \frac{1-\tanh a}{2}$ 를 대입하면 $\tanh'(a) = 1 - \tanh^2(a)$.

(c) $h'(a) = 1$ $(a > 0)$, $h'(a) = 0$ $(a < 0)$. ($a = 0$ 에서는 미분이 정의되지 않으며 보통 0으로 둔다.) 역전파에서 입력이 양수였던 성분은 upstream gradient를 **그대로** 전달하고, 음수였던 성분은 0으로 막는다: $\frac{\partial L}{\partial A} = \frac{\partial L}{\partial Z} \odot \mathbf{1}[A > 0]$.

(d) 역전파에서 sigmoid 층을 하나 지날 때마다 $\sigma'(a) \le \frac{1}{4}$ 가 곱해진다. k 개 층을 지나면 gradient가 많아야 $(\frac{1}{4})^k$ 배가 되어, 입력에 가까운 층일수록 gradient가 지수적으로 작아진다 (기울기 소실). $|a|$ 가 커서 sigmoid가 포화되면 $\sigma'(a) \approx 0$ 이므로 더 심해진다.

4. XOR 문제를 은닉층이 1개이고 출력층에 softmax를 사용하는 신경망으로 학습시키는 과정을 연습해 보자. 입력 $X = (x_1, x_2)$, 정답 레이블의 원핫 인코딩 $t = (t_1, t_2)$ 이고, XOR 데이터는 $(0,0) \to (1,0)$, $(1,0) \to (0,1)$, $(0,1) \to (0,1)$, $(1,1) \to (1,0)$ 이다. $A = (a_1, a_2)$, $Z = (z_1, z_2)$, $U = (u_1, u_2)$, $Y = (y_1, y_2)$ 라 하고, 가중치와 편이를

$$W^{(1)} = \begin{pmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix}, \quad B^{(1)} = \big(b_1^{(1)}, b_2^{(1)}\big), \quad W^{(2)} = \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} \end{pmatrix}, \quad B^{(2)} = \big(b_1^{(2)}, b_2^{(2)}\big)$$

라 하자. 신경망의 순전파는

$$A = XW^{(1)} + B^{(1)}, \quad Z = h(A), \quad U = ZW^{(2)} + B^{(2)}, \quad Y = \mathrm{softmax}(U),$$

$$l = -\sum_{i=1}^{2} t_i \log y_i$$

이다. 초기 가중치와 편이가

$$W_0^{(1)} = \begin{pmatrix} 2 & -1 \\ -2 & 2 \end{pmatrix}, \quad B_0^{(1)} = (1, 0), \quad W_0^{(2)} = \begin{pmatrix} -1 & 1 \\ -2 & 2 \end{pmatrix}, \quad B_0^{(2)} = (1, -1)$$

일 때,

데이터 $X_4 = (1,1)$, $t_4 = (1,0)$ 에 대한 온라인 학습을 진행하여 가중치를 업데이트하여라. h 는 ReLU ($x \ge 0$ 이면 x, $x < 0$ 이면 0) 이고 학습률은 1 이다. 순전파 값 A, Z, U, Y, l 과 역전파 값 $\frac{\partial l}{\partial U}$, $\frac{\partial l}{\partial W^{(2)}}$, $\frac{\partial l}{\partial B^{(2)}}$, $\frac{\partial l}{\partial Z}$, $\frac{\partial l}{\partial A}$, $\frac{\partial l}{\partial W^{(1)}}$, $\frac{\partial l}{\partial B^{(1)}}$ 을 차례로 구하라. (필요하면 $\dfrac{e^4}{1+e^4} \approx 0.98$, $\log\big(1+e^4\big) \approx 4.02$ 를 이용하라.)

풀이

순전파

$$A = XW_0^{(1)} + B_0^{(1)} = (2-2+1,\ -1+2+0) = (1,\ 1), \qquad Z = h(A) = (1,\ 1),$$

$$U = ZW_0^{(2)} + B_0^{(2)} = (-1-2+1,\ 1+2-1) = (-2,\ 2).$$

softmax의 분자와 분모에 e^2를 곱하면

$$Y = \mathrm{softmax}(U) = \left(\frac{e^{-2}}{e^{-2}+e^2},\ \frac{e^2}{e^{-2}+e^2}\right) = \left(\frac{1}{1+e^4},\ \frac{e^4}{1+e^4}\right),$$

$$l = -\log y_1 = -\log\frac{1}{1+e^4} = \log\left(1+e^4\right).$$

이제

$$c = \frac{e^4}{1+e^4} \qquad \left(= \sigma(4) \approx 0.982\right)$$

로 두면 $Y = (1-c,\ c)$이다. 이후의 모든 값은 c로 나타낼 수 있으므로 계산기 없이 식으로 끝까지 계산할 수 있다.

역전파

$$\frac{\partial l}{\partial U} = Y - t = (1-c-1,\ c-0) = (-c,\ c), \qquad \frac{\partial l}{\partial B^{(2)}} = \frac{\partial l}{\partial U} = (-c,\ c),$$

$$\frac{\partial l}{\partial W^{(2)}} = Z^\mathsf{T}\frac{\partial l}{\partial U} = \begin{pmatrix}1\\1\end{pmatrix}(-c,\ c) = \begin{pmatrix}-c & c\\ -c & c\end{pmatrix},$$

$$\frac{\partial l}{\partial Z} = \frac{\partial l}{\partial U}\left(W_0^{(2)}\right)^\mathsf{T} = (-c,\ c)\begin{pmatrix}-1 & -2\\ 1 & 2\end{pmatrix} = (c+c,\ 2c+2c) = (2c,\ 4c),$$

$$\frac{\partial l}{\partial A} = \frac{\partial l}{\partial Z}\odot h'(A) = (2c,\ 4c) \quad (A = (1,1) > 0\text{이므로 그대로}),$$

$$\frac{\partial l}{\partial W^{(1)}} = X^\mathsf{T}\frac{\partial l}{\partial A} = \begin{pmatrix}1\\1\end{pmatrix}(2c,\ 4c) = \begin{pmatrix}2c & 4c\\ 2c & 4c\end{pmatrix}, \qquad \frac{\partial l}{\partial B^{(1)}} = \frac{\partial l}{\partial A} = (2c,\ 4c).$$

갱신 (학습률 1: $W \leftarrow W - \frac{\partial l}{\partial W}$)

$$W_1^{(1)} = \begin{pmatrix}2-2c & -1-4c\\ -2-2c & 2-4c\end{pmatrix}, \qquad B_1^{(1)} = (1-2c,\ -4c),$$

$$W_1^{(2)} = \begin{pmatrix}-1+c & 1-c\\ -2+c & 2-c\end{pmatrix}, \qquad B_1^{(2)} = (1+c,\ -1-c), \qquad c = \frac{e^4}{1+e^4}.$$

수치 (문제에 주어진 $c \approx 0.98, l \approx 4.02$를 쓰면)

$$Y \approx (0.02,\ 0.98), \qquad \frac{\partial l}{\partial U} \approx (-0.98,\ 0.98), \qquad \frac{\partial l}{\partial Z} = \frac{\partial l}{\partial A} \approx (1.96,\ 3.92),$$

$$W_1^{(1)} \approx \begin{pmatrix}0.04 & -4.92\\ -3.96 & -1.92\end{pmatrix}, \qquad B_1^{(1)} \approx (-0.96,\ -3.92),$$

$$W_1^{(2)} \approx \begin{pmatrix} -0.02 & 0.02 \\ -1.02 & 1.02 \end{pmatrix}, \qquad B_1^{(2)} \approx (1.98,\ -1.98).$$

(정확한 값은 $c = 0.98201\ldots, l = 4.01815\ldots$ 이며 위의 값과 소수 셋째 자리에서만 다르다. 갱신된 가중치로 같은 데이터를 다시 계산하면 손실은 약 $4.02 \to 0.02$로 줄어든다.)

5. 정답이 $t = (0, 0, 1)$이고 network의 출력이 $Y = \text{softmax}(U) = (0.2,\ 0.3,\ 0.5)$일 때 cross entropy 손실 l과 $\frac{\partial l}{\partial U}$를 구하라. 경사하강법은 세 점수 u_1, u_2, u_3를 각각 어느 방향으로 움직이는가?

풀이

one-hot 정답이므로 $l = -\sum_k t_k \log y_k = -\log y_3 = -\log 0.5 = \log 2 \approx 0.693$. softmax와 cross entropy를 함께 쓰면

$$\frac{\partial l}{\partial U} = Y - t = (0.2,\ 0.3,\ -0.5).$$

경사하강법은 U를 $-\frac{\partial l}{\partial U}$ 방향으로 움직이므로 u_1, u_2는 **감소**, u_3는 **증가**한다. 즉 오답 class의 점수는 낮추고 정답 class의 점수는 높여, 정답 class의 확률 y_3을 키운다.

6. 이 절의 문제에서 $\boldsymbol{g}_k = \frac{\partial L}{\partial W}$는 k번째 단계의 gradient이고, $g_{k,i}$는 그 i번째 성분이다. 예제 함수는 $f(x, y) = \frac{1}{20}x^2 + y^2$, 시작점은 $(x_0, y_0) = (-7, 2)$이다.

모멘텀은 다음과 같이 매개변수 W를 갱신한다 (예제에서는 $W = (x, y)$, $\boldsymbol{g}_k = \nabla f(x_k, y_k)$이다).

$$\boldsymbol{v}_{k+1} = \beta\, \boldsymbol{v}_k - \alpha\, \boldsymbol{g}_k, \qquad W_{k+1} = W_k + \boldsymbol{v}_{k+1}, \qquad \boldsymbol{v}_0 = \boldsymbol{0}$$

예제 함수에서 모멘텀 ($\alpha = 0.1$, $\beta = 0.9$)으로 $\boldsymbol{v}_1$, (x_1, y_1), $\boldsymbol{v}_2$, (x_2, y_2)를 손으로 계산하라. x 방향과 y 방향의 속도가 어떻게 변하는지 설명하라.

풀이

$\boldsymbol{g}_k = \nabla f(x_k, y_k) = \big(x_k/10,\ 2y_k\big)$이다.

$$\boldsymbol{g}_0 = (-0.7,\ 4), \qquad \boldsymbol{v}_1 = -0.1\, \boldsymbol{g}_0 = (0.07,\ -0.4), \qquad (x_1, y_1) = (-6.93,\ 1.6),$$

$$\boldsymbol{g}_1 = (-0.693,\ 3.2),$$

$$\boldsymbol{v}_2 = 0.9\,(0.07,\ -0.4) - 0.1\,(-0.693,\ 3.2) = (0.1323,\ -0.68),$$

$$(x_2, y_2) = (x_1, y_1) + \boldsymbol{v}_2 = (-6.7977,\ 0.92).$$

설명. x 방향은 gradient의 부호가 매번 같으므로 속도가 누적되어 $0.07 \to 0.1323$으로 거의 두 배가 되었다 (gradient가 일정하면 속도는 최대 $\frac{\alpha}{1-\beta} = 10$배까지 커진다). 같은 학습률의 SGD라면 x는 매 단계 0.99배가 되어 $x_2 \approx -6.861$이므로, 모멘텀이 더 빨리 움직인다. y 방향도 아직 $y > 0$이라 gradient의 부호가 같아서 속도가 $-0.4 \to -0.68$로 커진다. 최솟값 $y = 0$을 지나치면 gradient의 부호가 바뀌어 반대 방향의 gradient가 더해지므로 속도가 상쇄되고, SGD에서와 같은 지그재그 진동이 줄어든다.