중간고사 연습문제

딥러닝개론및연습 · 2026년 2학기

1 Chain Rule, Gradient, Jacobian과 계산 그래프

1.1 다음 vector-valued function의 Jacobian을 구하라. [ChainRule 연습 3]

$$F(x_1, x_2) = \begin{bmatrix} x_1^2 + x_2 \\ \sin(x_1 x_2) \end{bmatrix}.$$

1.2 $q = x + y, p = xy, f = qp$로 정의된 계산 그래프를 생각하자. [추가]

(a) 계산 그래프를 그리고, $(x, y) = (1, 2)$에서 순전파로 q, p, f를 구하라.

(b) 각 연결의 local derivative를 쓰고, 역전파로 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$를 구하라. x에서 화살표가 두 개 나가는 것에 주의하라.

(c) $f(x, y) = (x + y)xy$를 직접 미분하여 (b)의 결과를 확인하라.

1.3 $G(x_1, x_2) = (x_1 x_2,\ x_1 + x_2), F(u, v) = (u^2,\ uv)$라 하자. [추가]

(a) $(x_1, x_2) = (1, 2)$에서 G의 Jacobian J_G와 $(u, v) = G(1, 2)$에서 F의 Jacobian J_F를 구하라.

(b) Jacobian 형태의 chain rule $J_{F\circ G} = J_F\, J_G$로 합성함수의 Jacobian을 구하라.

(c) $F \circ G$를 x_1, x_2의 식으로 직접 쓰고 미분하여 (b)의 결과를 확인하라.

2 Gradient Descent, Newton's Method, Gauss–Newton

1변수

2.1 $f(x) = \frac{1}{2}x^2 + \frac{1}{3}x^3 + \frac{1}{4}x^4$에 대하여 $x_0 = 1$에서 시작한다. [추가]

(a) 유일한 stationary point가 $x^* = 0$이고 그 점이 최솟점임을 보이라.

(b) Gradient Descent ($\alpha = 0.2$)로 x_1, x_2를 구하라.

(c) Newton's method로 x_1, x_2를 구하라.

(d) Newton's method가 현재점에서의 **이차 근사함수**의 최솟점을 다음 점으로 고른다는 것을 $q_k(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2$를 이용하여 보이라.

2.2 (참고만, 시험에는 안남) 수렴 차수에 관한 문제이다. $e_k = x_k - x^*$라 하자.

(a) Gradient Descent에서 평균값 정리를 이용하여 $e_{k+1} = \big[1 - \alpha f''(\xi_k)\big]e_k$임을 보이라. 이로부터 국소적으로 linear convergence가 일어나는 조건 $|1 - \alpha f''(x^*)| < 1$을 설명하라.

(b) Newton's method에서 Taylor 정리를 이용하여 $e_{k+1} = \dfrac{f'''(\xi_k)}{2f''(x_k)}e_k^2$임을 보이라.

(c) (a)와 (b)의 결과를 비교하여 Newton's method가 더 빨리 수렴하는 이유를 한 문장으로 설명하라.

(d) $f(x) = x^2 - 4x + 5$에 Newton's method를 쓰면 어떤 x_0에서 시작하든 한 번에 최솟점에 도달한다. 이유를 설명하라.

다변수

2.3 $f(x_1, x_2) = 3(x_1 - 6)^2 + (x_2 - 5)^2$에 대하여 다음 물음에 답하여라. [위 문제의 (a)와 관련됨]

(a) gradient ∇f와 Hessian H를 구하라.

(b) $\boldsymbol{x}_0 = (1, 1)$, $\alpha = 0.05$로 Gradient Descent를 두 번 적용하여 $\boldsymbol{x}_1, \boldsymbol{x}_2$를 구하라.

(c) Gradient Descent가 수렴하는 α의 범위를 구하라. 어느 방향이 학습률의 상한을 결정하는가?

(d) Newton's method를 한 번 적용하여 $\boldsymbol{x}_1$을 구하고, 왜 한 번에 최솟점에 도달하는지 설명하라.

2.4 $f(x, y) = x^4 + xy + y^2$에 대하여 $(x_0, y_0) = (1, 0)$에서 Newton step을 계산하라. 즉 $\boldsymbol{g}_0 = \nabla f(1, 0)$, $H_0 = H(1, 0)$를 구하고 연립방정식 $H_0 \boldsymbol{p}_0 = -\boldsymbol{g}_0$를 풀어 (x_1, y_1)을 구하라. [추가]

3 Neuron, 활성화 함수, 은닉층

이 절에서 σ는 sigmoid 함수

$$\sigma(a) = \frac{1}{1 + e^{-a}}$$

이다.

3.1 하나의 neuron $a = w_1 x_1 + w_2 x_2 + b$, $z = \sigma(a)$에 대해 $\nabla_{\boldsymbol{w}} z$를 구하라. [Neuron 연습 2]

3.2 $\ell = (z - t)^2$, $z = \sigma(wx + b)$에 대해 computational graph를 그리고 $\frac{\partial \ell}{\partial w}$, $\frac{\partial \ell}{\partial b}$를 local derivative의 곱으로 유도하라. [Neuron 연습 4]

3.3 활성화 함수가 identity, $\phi(a) = a$라고 하자. 두 affine layer $\boldsymbol{h} = W_1 \boldsymbol{x} + \boldsymbol{b}_1$, $\boldsymbol{y} = W_2 \boldsymbol{h} + \boldsymbol{b}_2$를 하나의 affine layer로 합칠 수 있음을 보이라. 이로부터 비선형 활성화 함수가 필요한 이유를 설명하라. [Neuron 연습 5]

3.4 활성화 함수의 미분에 관한 문제이다. [추가]

(a) $\sigma(a) = \frac{1}{1 + e^{-a}}$에 대하여 $\sigma'(a) = \sigma(a)\big(1 - \sigma(a)\big)$ 임을 보이고, $\sigma'(a)$의 최댓값과 그때의 a를 구하라.

(b) $\tanh(a) = 2\sigma(2a) - 1$임을 보이고, $\tanh'(a) = 1 - \tanh^2(a)$를 유도하라.

(c) ReLU $h(a) = \max(0, a)$의 도함수를 쓰라. 역전파에서 ReLU 계층은 gradient를 어떻게 전달하는가?

(d) (a)의 결과를 이용하여, sigmoid를 쓰는 층을 여러 개 쌓으면 역전파에서 gradient가 작아지는 이유를 설명하라.

3.5 [Neuron 과제 1]

다음 데이터 (x_i, t_i)가 주어졌다고 하자.

i	0	1	2	3	4	5	6	7
x	-2	-1	0	1	2	3	4	5
t	0	0	1	1	1	1	0	0

은닉층이 1층이고 두 개의 노드를 갖는 함수로 주어진 데이터를 회귀하고자 한다. 활성화 함수가 ReLU $h(x) = \max(0, x)$ 일 때 ($h'(0) = 0$으로 약속한다)

$$\begin{cases} a_1 = xw_1^{(1)} + b_1^{(1)} \\ a_2 = xw_2^{(1)} + b_2^{(1)} \end{cases}, \qquad \begin{cases} z_1 = h(a_1) \\ z_2 = h(a_2) \end{cases}, \qquad y = z_1 w_1^{(2)} + z_2 w_2^{(2)} + b^{(2)}$$

이고, 행렬로 $W^{(1)} = (w_1^{(1)}, w_2^{(1)})$, $B^{(1)} = (b_1^{(1)}, b_2^{(1)})$, $W^{(2)} = \begin{pmatrix} w_1^{(2)} \\ w_2^{(2)} \end{pmatrix}$, $B^{(2)} = (b^{(2)})$, $A = (a_1, a_2)$, $Z = (z_1, z_2)$라 하면

$$A = (x)W^{(1)} + B^{(1)}, \qquad Z = h(A), \qquad y = ZW^{(2)} + B^{(2)}$$

이다. 오차를 $e = y - t$, 제곱 오차를 $l = e^2$이라 하자. 데이터 $(x_3, t_3) = (1, 1)$과 초깃값

$$W_0^{(1)} = (1, 0), \quad B_0^{(1)} = (0, 1), \quad W_0^{(2)} = \begin{pmatrix} 3 \\ 2 \end{pmatrix}, \quad B_0^{(2)} = 0$$

에 대하여 다음 물음에 답하여라.

(a) 순전파로 정해지는 변수값 A, Z, y, e, l의 값을 구하여라.

(b) 역전파로 정해지는 편미분 $\frac{\partial l}{\partial e}$, $\frac{\partial l}{\partial y}$, $\frac{\partial l}{\partial W_0^{(2)}}$, $\frac{\partial l}{\partial B_0^{(2)}}$, $\frac{\partial l}{\partial Z}$, $\frac{\partial l}{\partial A}$, $\frac{\partial l}{\partial W_0^{(1)}}$, $\frac{\partial l}{\partial B_0^{(1)}}$, $\frac{\partial l}{\partial x}$의 값을 구하여라.

(c) $\alpha = 0.01$일 때 경사하강법을 적용하여 $W_1^{(1)}, B_1^{(1)}, W_1^{(2)}, B_1^{(2)}$을 구하여라.

4 다중분류: Affine 계층, Softmax, Cross Entropy, 미니배치

4.1 MNIST network에서 입력 $l = 784$, 은닉 $m = 100$, 출력 $n = 10$, 미니배치 크기 $h = 100$이다. $X, W^{(1)}, B^{(1)}, A, Z, W^{(2)}, B^{(2)}, U, Y, T$의 shape을 쓰고, 학습해야 하는 parameter의 총 개수를 구하라. [다중분류 연습 1]

4.2 $U = (1, 2, 3)$일 때 $Y = \text{softmax}(U)$를 구하라.

4.3 정답이 $t = (0, 0, 1)$이고 network의 출력이 $Y = (0.2, 0.3, 0.5)$일 때 cross entropy 손실 l과 $\frac{\partial l}{\partial U}$를 구하라. 경사하강법은 세 점수 u_1, u_2, u_3를 각각 어느 방향으로 움직이는가? [다중분류 연습 3]

4.4 (두 확률분포의 비교) 같은 표본공간 $\{1, 2, 3\}$ 위의 기준 분포 p와, p를 근사하는 두 분포 q_A, q_B가 있다.

$$p = (0.7,\ 0.2,\ 0.1), \qquad q_A = (0.6,\ 0.3,\ 0.1), \qquad q_B = (0.7,\ 0.1,\ 0.2)$$

entropy, cross entropy, KL divergence는 각각

$$H(p) = -\sum_i p_i \log p_i, \qquad H(p,q) = -\sum_i p_i \log q_i, \qquad D_{\mathrm{KL}}(p \,\|\, q) = \sum_i p_i \log \frac{p_i}{q_i}$$

이다 ($\log$는 자연로그이며 $\log 0.7 \approx -0.357$, $\log 0.6 \approx -0.511$, $\log 0.3 \approx -1.204$, $\log 0.2 \approx -1.609$, $\log 0.1 \approx -2.303$을 이용하라). [추가]

(a) p와 q_A, p와 q_B의 확률질량함수를 각각 겹쳐 막대그래프로 그려라. 성분별 차이의 제곱합 $\sum_i (p_i - q_i)^2$을 q_A, q_B에 대해 각각 구하라.

(b) $H(p)$를 구하라.

(c) $H(p, q_A)$, $H(p, q_B)$와 $D_{\mathrm{KL}}(p \,\|\, q_A)$, $D_{\mathrm{KL}}(p \,\|\, q_B)$를 구하라. cross entropy로 보면 어느 분포가 p에 더 가까운가?

(d) (a)의 제곱합은 같은데 (c)의 값은 왜 다른가? q_B가 결과 2에 준 확률과 그때의 놀라움 $-\log q_2$를 이용하여 설명하라.

(e) $H(p,q) = H(p) + D_{\mathrm{KL}}(p \,\|\, q)$임을 보이라. p가 고정되어 있을 때 $H(p,q)$를 최소화하는 것이 $D_{\mathrm{KL}}(p \,\|\, q)$를 최소화하는 것과 같은 이유와, $H(p,q)$가 가장 작아지는 q를 설명하라.

(f) 기준 분포가 one-hot 정답 $t = (1, 0, 0)$이라면 $H(t, q_A)$, $H(t, q_B)$는 각각 얼마인가? (c)와 비교하여 어느 분포가 더 좋은지가 바뀌는 이유를 설명하라.

4.5 Affine 계층 $A = XW + B$에서

$$X = (1,\ 2), \qquad W = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 1 & 0 \end{pmatrix}, \qquad B = (0,\ 1,\ 0), \qquad \frac{\partial l}{\partial A} = (1,\ -1,\ 2)$$

일 때 A, $\frac{\partial l}{\partial X}$, $\frac{\partial l}{\partial W}$, $\frac{\partial l}{\partial B}$를 구하라. [다중분류 연습 4]

4.6 softmax와 cross entropy를 함께 쓰는 출력층에 대하여 다음을 보이라. [추가]

(a) 데이터 하나에 대하여 $l = -\sum_k t_k \log y_k$, $Y = \mathrm{softmax}(U)$이면 $\frac{\partial l}{\partial U} = Y - T$이다.

(b) 미니배치 h개의 평균 손실 $L = \frac{1}{h}\sum_i l_i$에 대해서는 $\frac{\partial L}{\partial U} = \frac{1}{h}(Y - T)$이다.

(c) one-hot 정답에서 cross entropy는 $-\log$(정답 class의 확률)이 됨을 보이고, 정답 class의 확률이 1, 0.5, 0.01일 때의 손실을 비교하라.

4.7 훈련 데이터 55000개를 미니배치 크기 100으로 학습한다. 한 epoch은 몇 iteration인가? 10 epoch 동안 parameter는 몇 번 갱신되는가? 온라인 학습, full-batch 학습, 미니배치 학습의 차이를 설명하라. [추가]

4.8 [다중분류 과제 1]

XOR 문제를 은닉층이 1개이고 출력층에 softmax를 사용하는 신경망으로 학습시키는 과정을 연습해 보자. 입력 $X = (x_1, x_2)$, 정답 레이블의 원핫 인코딩 $t = (t_1, t_2)$이고, XOR 데이터는 $(0,0) \to (1,0)$, $(1,0) \to (0,1)$, $(0,1) \to (0,1)$, $(1,1) \to (1,0)$이다. $A = (a_1, a_2)$, $Z = (z_1, z_2)$, $U = (u_1, u_2)$, $Y = (y_1, y_2)$라 하고, 가중치와 편이를

$$W^{(1)} = \begin{pmatrix} w_{11}^{(1)} & w_{12}^{(1)} \\ w_{21}^{(1)} & w_{22}^{(1)} \end{pmatrix}, \quad B^{(1)} = \left(b_1^{(1)}, b_2^{(1)}\right), \quad W^{(2)} = \begin{pmatrix} w_{11}^{(2)} & w_{12}^{(2)} \\ w_{21}^{(2)} & w_{22}^{(2)} \end{pmatrix}, \quad B^{(2)} = \left(b_1^{(2)}, b_2^{(2)}\right)$$

라 하자. 신경망의 순전파는

$$A = XW^{(1)} + B^{(1)}, \quad Z = h(A), \quad U = ZW^{(2)} + B^{(2)}, \quad Y = \text{softmax}(U),$$

$$l = -\sum_{i=1}^{2} t_i \log y_i$$

이다. 초기 가중치와 편이가

$$W_0^{(1)} = \begin{pmatrix} 2 & -1 \\ -2 & 2 \end{pmatrix}, \quad B_0^{(1)} = (1, 0), \quad W_0^{(2)} = \begin{pmatrix} -1 & 1 \\ -2 & 2 \end{pmatrix}, \quad B_0^{(2)} = (1, -1)$$

일 때,

데이터 $X_4 = (1, 1), t_4 = (1, 0)$에 대한 온라인 학습을 진행하여 가중치를 업데이트하여라. h는 ReLU ($x \geq 0$이면 $x, x < 0$이면 0)이고 학습률은 1이다. 순전파 값 A, Z, U, Y, l과 역전파 값 $\frac{\partial l}{\partial U}$, $\frac{\partial l}{\partial W^{(2)}}$, $\frac{\partial l}{\partial B^{(2)}}$, $\frac{\partial l}{\partial Z}$, $\frac{\partial l}{\partial A}$, $\frac{\partial l}{\partial W^{(1)}}$, $\frac{\partial l}{\partial B^{(1)}}$을 차례로 구하라. [다중분류 과제 1]

5 학습 관련 기술

매개변수 갱신 (optimizer)

이 절의 문제에서 $\boldsymbol{g}_k = \frac{\partial L}{\partial W}$는 k번째 단계의 gradient이고, $g_{k,i}$는 그 i번째 성분이다. 예제 함수는 $f(x, y) = \frac{1}{20}x^2 + y^2$, 시작점은 $(x_0, y_0) = (-7, 2)$이다.

5.1 $f(x, y) = \frac{1}{20}x^2 + y^2$에서 SGD가 발산하지 않는 학습률 α의 범위를 구하라. 또 이 범위 안에서 x 방향의 수렴이 가장 빠른 α와 그때 x가 한 단계에 몇 배가 되는지 구하라. [학습기술 연습 1]

5.2 모멘텀 $\boldsymbol{v}_{k+1} = \beta \boldsymbol{v}_k - \alpha \boldsymbol{g}_k, W_{k+1} = W_k + \boldsymbol{v}_{k+1}$에서 gradient가 매 단계 같은 값 $\boldsymbol{g}$로 일정하다고 하자. $\boldsymbol{v}_0 = \boldsymbol{0}$일 때 $\boldsymbol{v}_k$를 구하고, $k \to \infty$일 때 $\boldsymbol{v}_k \to -\frac{\alpha}{1-\beta}\boldsymbol{g}$임을 보이라.
[학습기술 연습 2]

5.3 예제 함수에서 모멘텀 ($\alpha = 0.1, \beta = 0.9$)으로 $\boldsymbol{v}_1, (x_1, y_1), \boldsymbol{v}_2, (x_2, y_2)$를 손으로 계산하라. x 방향과 y 방향의 속도가 어떻게 변하는지 설명하라. [추가]

5.4 시작점 $(-7, 2)$에서 AdaGrad ($\alpha = 1.5$)로 두 번째 단계 (x_2, y_2)를 손으로 계산하라 (ε은 무시한다). 결과를 $(-4.573,\ 0.136)$과 비교하라. [학습기술 연습 3]

가중치의 초깃값

5.5 (참고만..) $a = \sum_{i=1}^{n} z_i w_i$에서 $z_i = \max(0, a_i')$이고 a_i'이 평균 0인 대칭 분포를 따를 때 $\mathbb{E}[z_i^2] = \frac{1}{2}\text{Var}(a_i')$임을 보이고, 이로부터 He 초깃값 $\text{Var}(w) = \frac{2}{n}$을 유도하라. ($w_i$는 평균 0이고 z_i와 독립이다.) 왜 $\text{Var}(z_i)$가 아니라 $\mathbb{E}[z_i^2]$이 필요한가? [학습기술 연습 7]

5.6 입력 node 수가 $n = 784, 100$인 층에서 Xavier 초깃값과 He 초깃값의 표준편차를 각각 구하라. sigmoid와 ReLU에는 각각 어느 초깃값을 쓰는가? [추가]

5.7 (참고만..) 은닉층이 5개 (각 100개 node, ReLU)인 network의 가중치를 표준편차 0.01로 초기화하였다. [추가]

(a) 순전파에서 한 층을 지날 때마다 활성화값의 크기가 대략 몇 배가 되는지 $\sqrt{n\,\mathrm{Var}(w)/2}$로 추정하라.

(b) Affine 계층의 역전파 $\frac{\partial L}{\partial X} = \frac{\partial L}{\partial A}W^{\mathsf{T}}$, $\frac{\partial L}{\partial W} = X^{\mathsf{T}}\frac{\partial L}{\partial A}$를 이용하여, 출력에 가까운 층과 입력에 가까운 층의 가중치 gradient가 각각 어떤 이유로 작아지는지 설명하라.

(c) sigmoid에서 가중치가 너무 클 때 일어나는 기울기 소실은 (b)와 원인이 어떻게 다른가?

배치 정규화

배치 정규화는 미니배치 (h개)에서 node마다

$$\mu_B = \frac{1}{h}\sum_{i=1}^{h} x_i, \qquad \sigma_B^2 = \frac{1}{h}\sum_{i=1}^{h}(x_i-\mu_B)^2, \qquad \hat{x}_i = \frac{x_i-\mu_B}{\sqrt{\sigma_B^2+\varepsilon}}, \qquad y_i = \gamma\hat{x}_i + \beta$$

를 계산한다.

5.8 어떤 node의 미니배치 값이 (1, 2, 3, 6)이고 $\gamma = 2$, $\beta = 1$이다 (ε은 무시한다). μ_B, σ_B^2, $\hat{x}_i$, y_i를 구하라. $\hat{x}_i$의 평균과 분산은 얼마인가? [추가]